
FDE Handbook

前线手册

从需求识别到生产交付

创建者 空格

为谁创建 想转型 FDE 的工程师和产品经理、正在组建 FDE 团队的 AI 公司、需要把 AI 落进业务的企业负责人

基于 Palantir / OpenAI / AWS / Anthropic 公开实践，MIT NANDA 与 LinkedIn 调研数据

全书 8 篇 32 章 + 8 个附录

最后更新 2026-08-31

目录

前言

Part 1 认识 FDE

- §01 FDE 的爆发，说明 AI 的瓶颈换了位置
- §02 顺序：FDE 工作里唯一不能变的东西
- §03 FDE 和它周围的五个岗位
- §04 六个问题，判断这是不是真 FDE

Part 2 能力篇：谁能做 FDE

- §05 能力模型：四个象限，缺哪个都会翻车
- §06 四条转型路径，起点不同，缺的东西也不同
- §07 个人工作方式：FDE 每天在对抗什么
- §08 团队：一个 Pod 要几个人

Part 3 原理篇：FDE 必须理解的底座

- §09 模型的边界：知道它什么时候会骗你
- §10 Context Engineering：决定模型看到什么
- §11 Harness Engineering：决定模型怎么持续工作
- §12 企业软件底座：集成、身份、可观测

Part 4 需求篇：企业到底需要什么 AI

- §13 企业 AI 需求的五层分类
- §14 七类反复出现的企业问题
- §15 需求筛选：哪些现在不该做

Part 5 实施篇：Runtime Harness

- §16 Outcome Contract：写在代码之前
- §17 现场调研与 Context Audit
- §18 Workflow Contract：把流程写成状态机
- §19 Context System：来源、权威、时效与权限
- §20 Agent Harness：工具、状态、失败与接管
- §21 Eval Harness：验证业务状态，不看模型自述
- §22 Operational Harness：从影子运行到有条件自治

Part 6 交付篇：Delivery Harness

- §23 客户筛选与付费诊断

§24 范围收缩、报价与 SOW

§25 甲方依赖：项目失败最常见的非技术原因

§26 变更管理与验收证据

§27 上线培训、采用率与交接

Part 7 推演篇：把方法论走一遍

§28 推演一：企业知识助手

§29 推演二：客服处理 Agent

§30 推演三：跨系统执行 Agent

Part 8 资产篇：让下一单不从零开始

§31 复利循环：把项目变成能力

§32 什么时候不需要 FDE

附录

前言

这本书想解决什么

市面上关于 FDE 的中文内容已经不少，但大部分停在两个位置：一个是岗位科普，讲 FDE 是什么、薪资多少、怎么转行；另一个是原则总结，讲要深入客户、快速迭代、沉淀复用。这些都对，但读完仍然回答不了一个问题——星期一早上你坐在客户的会议室里，第一件事该做什么，第一份交付物长什么样，什么条件下才允许上线。

这本书想补的就是这一段。它按四个层次往下走：企业到底有哪些 AI 需求，这些需求怎么翻译成可执行的系统，系统怎么被验证和上线，项目怎么被交付并留下可复用的资产。

这本书的依据，以及它的边界


先说清楚这本书是怎么写出来的，免得你把它当成第一手的项目复盘。

它建立在三类材料上：一是 Palantir、OpenAI、AWS、Anthropic 的公开文件和工程博客；二是 MIT NANDA、LinkedIn 等机构的调研数据；三是一线团队在公开渠道写下的交付记录。所有关键数字和判断在正文里都标了出处，你可以自己去核。

书里的方法论是我从这些材料里抽象出来的，逻辑我认为站得住，但它不是我在几十个客户现场亲手验证过的结论。**凡是我的推断，正文里会写成「我认为」「我的判断是」，不会伪装成经验。**

具体的行业案例我也没有编。找不到可靠来源的数字，宁可不写。

全书的主轴只有一个结构：



Part 1 认识 FDE

这一篇回答三个问题：FDE 为什么在 2026 年变热，它工作时不能打乱顺序是什么，以及它跟周围那几个看起来很像的岗位差在哪。

§01 FDE 的爆发，说明 AI 的瓶颈换了位置

2026 年 8 月，我花了大半个月集中读 FDE 的资料。招聘报告、大模型公司的公开动作、一线团队的复盘，加起来三十多份。

最先抓住我的是一个数字。

LinkedIn 在 2026 年 1 月的劳动力市场报告里给出，2023 到 2025 年，FDE 类岗位增长了 42 倍。同期 AI Engineer 增长 13 倍。

单看这个，容易把 FDE 当成又一个被炒热的头衔。

但把资料摊开一起读，我更倾向于另一个解释：**招聘市场只是结果，真正变的是企业 AI 的瓶颈位置。**

那个 95%，比 42 倍更值得看

MIT Media Lab 的 NANDA 项目在 2025 年 7 月发过一份报告，The GenAI Divide: State of AI in Business 2025。样本是 150 场业务负责人访谈、350 份员工问卷、300 个公开部署案例。

结论：企业投进生成式 AI 的 300 到 400 亿美元里，95% 的项目没有产生可衡量的损益影响。

这个数字传得很广，但传播过程里最重要的部分被丢了——**它的归因不是模型。**

报告把失败主要归到三件事：数据就绪度、工作流集成、缺少反馈闭环。MIT 给这个现象起了个名字，learning gap。

同一份报告里还有一组对比：外部伙伴主导的部署约 67% 进了生产，企业自建的只有 33%。

前两年行业的注意力都在模型上。谁分数高，谁窗口大，谁 API 便宜。

到 2026 年，这些差距对多数企业已经不构成决策障碍——能买到的模型，做一个像样的 AI 应用足够了。

让项目停下来的换成了另一批东西。

数据散在七八个系统里。业务规则只存在于几个老员工的判断里。二十年前的核心系统没有 API。谁能访问哪张表说不清楚。模型好不好没有统一判断标准。做错了没有撤回路径。

这些问题不会因为下一个模型发布而消失。

企业已经买到了模型，但没拿到能跑的业务能力。FDE 就出现在这段落差里。

从 Demo 到生产，中间隔着一整家企业

做一个 AI Demo 现在有多快？

接一个模型 API，喂进去几份文档，套一个聊天界面，一两天就能演示。

会议室里效果通常不错。因为演示数据是挑过的，流程只有一条，操作的人知道系统能干什么，也知道不该问什么。


离开会议室，情况立刻不一样。

同一个问题可能有三份互相矛盾的答案。制度文件写的是一套流程，员工实际执行的是另一套。关键规则从来没进过数据库，只在工龄十年那位同事的判断里。

还有一类问题更麻烦：Agent 可以生成一张采购单，但它不知道超过某个金额必须先走区域负责人。这条规则可能哪份文档里都没写。

就算模型每一步的成功率是 95%，一条十步的流程跑下来，整体也只剩六成。

企业 AI 的复杂度，大部分出现在模型之外。



模型只占最上面那一格，企业买的是最下面那一格。

FDE 的工作，就是穿过中间这五道关。

核心判断

Demo 验证的是模型能力，生产系统验证的是企业能力。这两件事之间隔的不是一段开发工作，是一次小规模的组织改造。

大模型公司正在把「部署」变成核心能力

2026 年 5 月，OpenAI 宣布成立 Deployment Company，初始投入超过 40 亿美元，通过收购 Tomoro 引入约 150 名部署工程师。

它对这支团队的描述相当具体：进入企业，连接客户的数据、工具、控制系统和业务流程，把少量高价值场景做成能长期运行的生产系统。

一个月后，AWS 宣布投入 10 亿美元建 FDE 组织，计划把数千名工程师放进客户团队。

AWS 还提出了一个我觉得很值得抄的词——**Delivery Harness**。领域本体、Context Graph、评估框架、MCP Server、Agent 运维工具，装进同一套交付体系。每做完一个客户，这套东西厚一层。

Anthropic 走的是生态路线，自有 FDE、Applied AI Engineer 加上咨询伙伴，和 Accenture 的合作里包含约三万名 Claude 专业人员。

三家的方向一致：从卖模型和 API，往客户的工作流内部移动。

原因也不复杂。模型只有真正进入业务，调用量、续费和组织扩展才会发生。

对个人来说，这件事的含义是：**FDE 这个位置同时靠近客户的业务结果和 AI 公司的收入，中间没有隔层。**

FDE 交付的是一段跑起来的业务流程

企业提出的 AI 需求，通常不能直接开发。

「我们想做一个企业知识库」「能不能来个客服 Agent」「AI 能不能替掉一部分重复岗位」——这些话说明企业愿意花钱，但没说明系统该长什么样。

FDE 的第一份工作是把它问下去。

这些活现在谁在干？每天多少次？输入来自哪几个系统？哪些判断有明文规则，哪些靠经验？做错了能不能撤销？第一阶段准备把哪个数字往哪个方向推？

拿 AI 客服举例。系统能回答问题，不代表项目成功。

真正要看的可能是首次解决率、人工转接率、平均处理时长、单张工单成本。

对高风险问题还得说清楚：哪些回复必须人工确认，哪些客户信息模型不能碰，回复错了怎么撤回，客户投诉之后谁接手。


这些答案凑齐了，才有一份能开发的东西。第 16 章会把它写成一份正式交付物，叫 Outcome Contract。

FDE 最后交出去的，是一段已经在跑的业务流程：有人在用，异常有人管，结果能被衡量。

FDE 同时在建两套 Harness

看完这些资料，我发现只用"实施流程"解释 FDE 是不够的。

一名 FDE 实际上在建两套系统。一套保证项目能交出来，一套保证 AI 能稳定工作。



Delivery Harness 管项目边界：这个客户值不值得做，第一阶段做哪一块，甲方得先给什么人和什么权限，怎么算验收通过，需求变了范围和预算怎么动。

Runtime Harness 管系统边界：Agent 每一步能看到哪些信息，怎么调工具，状态存在哪，哪些动作必须人批，怎么验证它真的改变了业务状态。

两套靠 Outcome Contract 连起来。

少了这份契约，技术团队不知道该优化什么，客户也不知道该验收什么。项目可能做出一堆功能，却回答不了最简单的那个问题：这套 AI 到底改变了什么。

这两套 Harness 会分别占掉这本书的第五篇和第六篇。

判断标准：下一单会不会更容易

FDE 和传统驻场交付最容易混。

都进客户现场，都写代码，都接系统，都处理需求。区别在项目结束以后。

传统项目围着人天和验收单转。一个客户做完，下一个从头开始。代码散在各自的项目仓库里，现场发现的问题没进产品路线图。团队一扩大，交付成本同比例上涨。

FDE 模式要跑通另一条循环：现场踩的坑变成评估用例，重复出现的对接变成 Connector 或 MCP Server，业务规则沉成 Context Schema，稳定下来的实施流程变成 Harness Template。

客户拿到业务结果，产品团队拿到新的通用能力，下一位同事不用重新踩一遍。

如果每一单都从空白开始，那就只是给传统交付换了个新名字。

企业 AI 最后的胜负，我猜不会在模型排行榜上分出来。

更可能是在一间普通的会议室里：一个 FDE 坐在业务员旁边，看他同时开着五个系统，听他解释为什么制度写的是一套、实际操作是另一套。

模型已经准备好了，现在缺的是理解企业的人。

下一章讲 FDE 工作里唯一不能打乱的东西——顺序。

本章引用

- [The GenAI Divide: State of AI in Business 2025](#), MIT Media Lab NANDA, 2025-07
- [LinkedIn 劳动力市场报告](#), 2026-01
- [OpenAI Deployment Company](#)
- [AWS Forward Deployed Engineering for Partners](#)
- [Anthropic × Accenture](#)

§02 顺序：FDE 工作里唯一不能变的东西

这一章我写废过一版。

那一版叫“进场四周”，第 0 周干什么、第 1 周干什么，排得整整齐齐。写完自己看着就别扭。

因为它假设了一件不存在的事：所有企业的项目节奏是一样的。

一个客服工单分类，两周可能就够了。一个要动 ERP 的库存补货流程，八周只够把数据摸清楚。把周历写死，等于告诉读者一件他到现场第二天就会发现是假的事。

真正固定下来的不是时长，是顺序。

这一章讲的就是这个顺序，以及为什么它一被打乱，项目就会掉进那 95% 里。

先看那个 95%

MIT Media Lab 的 NANDA 项目在 2025 年 7 月发了一份报告，叫 The GenAI Divide: State of AI in Business 2025。样本是 150 场业务负责人访谈、350 份员工问卷、300 个公开部署案例。

结论是：企业砸进生成式 AI 的 300 到 400 亿美元里，**95% 的项目没有产生可衡量的损益影响。**

这个数字被传得很广，但传播过程中最重要的那部分被丢掉了——报告的归因。

它把失败主要归到三件事上：数据就绪度、工作流集成、缺少反馈闭环。模型本身不在主要原因里。MIT 给这个现象起了个名字，叫 learning gap，学习鸿沟。


还有一个对比我觉得更狠。同一份报告里，外部伙伴主导的部署有大约 67% 进了生产，企业自建的只有 33%，差了一倍。

你可能会说，这是卖服务的人爱引的数据。但把这两组数字放一起看，指向是一致的：**决定成败的不是谁的模型强，是没有人真的把这套东西装进工作流。**

而数据就绪、工作流集成、反馈闭环这三件事，恰好是被跳过最多的三个前置步骤。

四个依赖，倒过来就出事

我把 FDE 的工作拆成四段，它们之间是依赖关系，不是时间关系。



这四段可以压缩，可以并行，但不能换序。

下面逐个讲为什么。

依赖一：事实先于结果

你没法给一个没看过的流程定义成功。

这句话听着像废话，但企业项目里跳过它是常态。常见形式是：客户在会议室里描述一遍流程，你记下来，回去就开始设计。

问题在于，会议室里的描述是制度版本，不是执行版本。

制度文件写的是流程应该怎么跑。实际执行里有大量没进过文档的东西：某个环节因为系统太慢被绕过去了、某类客户默认走特批、某个字段大家约定俗成填的是另一个意思。

制度写的和实际做的之间那个差值，就是这个项目最危险的地方。

要拿到这个差值，只能去看人怎么干活。坐在操作员旁边，看他处理真实案例，全程不打断。

看的时候，我认为有一个信号最值钱：**他在哪里停顿。**

流畅走完的步骤，说明有明确规则，AI 大概率能学。停下来想一下的、或者转头去问同事的，说明这里是隐性经验。这些地方就是后面 Agent 会出错的地方，也是评估集里最该覆盖的地方。

访谈也要做，但问题得挂在具体案例上。「这一单你为什么没走标准审批」能问出东西，「你们的审批流程是怎样的」只会拿回制度版本。

这一步做完，你手上有两样东西：真实流程长什么样，以及有多少种不正常的情况。

至于这需要三天还是三周，取决于流程有多复杂、能约到多少人。没有标准答案。

依赖二：结果先于系统

事实清楚了，接下来要定的是这个项目算不算成功。

这一步的产物我叫它 Outcome Contract，结果契约。它要回答的问题是固定的：

什么条件触发这件事。做完之后哪个业务状态发生了改变。谁是这个结果的负责人。做错一次的代价有多大。哪些动作必须人工批准。成功、失败、部分成功分别怎么判断。

注意这些问题里没有一个是技术问题。

Outcome Contract 描述的是业务状态的改变，不是模型的行为。

差别在哪？「Agent 能准确回答产品问题」是模型行为，「订单状态类工单的人工转接率从 X 降到 Y」是业务状态。前者做完了没人能验收，后者可以直接写进合同。

这一步同时要做的是把范围砍小。客户第一次提的需求，基本都是他们能想到的最大版本。你要从里面切一块出来，满足四个条件：发生得够频繁、结果能衡量、数据拿得到、做错了能恢复。

第四个条件最容易被忽略。一个**错误不可回滚的场景，不该作为第一个项目**。不是因为技术上做不到，是因为你需要几个月的运行数据来建立信任，而不可回滚的场景不给你犯错的额度。

依赖三：判据先于优化

这一步最容易被跳过，我认为也最不该跳过。

多数团队的顺序是先把系统搭起来，跑通了再想怎么测。这个顺序在企业项目里会出一个很隐蔽的问题：

系统一旦存在，它能做到的事会变成标准，它做不到的事会被解释成不重要。

这不是谁不诚实，是人在有了具体对象之后就很难再回到抽象判断。所以判据要在系统之前定下来。

原料就是前面看到的真实案例，把它们和预期结果一起写成测试集。除了正常情况，还要补上这几类：

用例类型	检查什么	为什么 Demo 阶段测不到
边界	金额临界、时间临界、多条件叠加	演示数据是挑过的
信息缺失	关键字段没给的时候会不会瞎编	演示输入都是完整的
上下文冲突	两份文档说法不一致时选哪个	演示只放了一份文档
权限越界	请求超出该角色能看的范围	演示账号通常是管理员
必须拒绝	高风险请求会不会该停不停	演示不会故意问危险问题
下游失败	目标系统超时或报错时会不会重复写入	演示环境不会挂

后面四类是企业场景特有的。它们在 Demo 里永远不会出现，在生产环境里每天都出现。

还有一个判据本身的问题：**用什么来判断任务完成了。**

Anthropic 在讲 Agent 评估时举过一个例子，我觉得是整件事里最清楚的一个：订票 Agent 说"已为您预订"，你要去数据库里查有没有真的产生那张订单。

模型的自我陈述不能作为完成的证据。评估必须检查最终的环境状态。

这条在企业里的分量比在 Demo 里重得多，因为企业的下游系统会真的被写入。

依赖四：验证先于放量

系统能跑了，不等于可以交给它。

中间需要一段让它在真实数据上跑、但不产生任何对外影响的时间。真实请求进来，人正常处理，系统在旁边也处理一遍，两边结果存下来做对比。

这一段能暴露的东西，测试环境里几乎看不到：真实数据有多脏、请求的实际分布和你以为的差多少、高峰期的延迟、以及一批你在流程还原阶段压根没见过的情况。

跑出来的偏差要分类，不能一股脑拿去改提示词。

上下文缺失，去补 Context Registry。规则理解错，去改流程契约。工具调用出问题，去改 Agent Harness。模型确实做不到的，划出去交给人工。

分类这一步决定了你是在修系统，还是在给系统打补丁。

之后的放量也不是一个开关，而是逐级释放权限：只读建议、人工批准后执行、小流量自动执行、有条件自治。每一级都要有数字化的通过门槛，比如准确率、误操作率、人工介入率、成本和延迟。

关于失败模式，Lilian Weng 在 2026 年 7 月那篇讲 harness engineering 的文章里，引了 Trehan 和 Chopra 归纳的六种反复出现的模式：偏向训练数据的默认答案、执行压力下的实现漂移、记忆和上下文退化、过度乐观、领域知识不足、以及弱科学品味。

这六条是从编码 Agent 场景里总结的，我认为可以直接搬到企业场景，只要把"代码库"换成"企业业务系统"。尤其是"过度乐观"和"实现漂移"这两条——Agent 为了尽快结束任务而走捷径，在企业里的后果比在代码库里严重得多。

为什么大家总是倒着做

顺序讲完了。但真到项目里，绝大多数团队还是从最后一步往前做：先搭个能演示的东西，再补测试，再定目标，最后才发现流程理解错了。

原因不复杂。

倒着做，每一步都有即时反馈；正着做，前三步都拿不出可以演示的东西。

客户第二周就会问"能看到点什么吗"。你的老板第三周就会问"进度怎么样"。而这时候你手上只有一份流程地图和一份契约草稿，展示起来相当难看。

我认为这是 FDE 这个岗位真正难的地方。它需要的不是更强的技术，是在没有可展示成果的那几周里，顶住压力把事实搞清楚。

如果非要给一个折中，我的建议是把"事实"这一段本身做成交付物卖给客户——付费诊断。输出流程地图、数据可行性判断和收缩后的第一阶段范围。这份东西对客户独立有价值，就算后面不合作，他也拿到了一份能用的现状梳理。

它同时解决了另一个问题：免费做的诊断，客户不会认真配合，人也约不齐。

顺序对了，产物是自然长出来的

最后说交付物。

我不打算给一份"标准六件套", 因为不同项目该产出什么确实不一样。一个内部知识问答不需要写审批链, 一个跨系统写入的 Agent 光权限矩阵就能写十页。

但如果顺序是对的, 每一段会自然留下一样可检验的东西:

依赖段	自然产物	检验方式
事实	真实流程和异常清单	拿给一线操作员看, 他认不认
结果	Outcome Contract	客户业务负责人愿不愿意签字
判据	评估集	里面有没有当前系统会答错的用例
系统	可跑通的链路 + 基线分数	有没有一个可比较的初始数字
放量	分级门槛	门槛是不是数字, 而不是"效果不错"

最后一列比第二列重要。产物本身很容易糊弄, 一份 PPT 也能叫流程地图。检验方式糊弄不了。

如果一线操作员看完流程图说"我们不这么干", 那前面的活就得重做, 不管你已经写了多少代码。

这一章讲的是顺序。下一章处理另一个绕不开的问题: 这些活里有不少原本属于产品经理、解决方案架构师和咨询顾问, FDE 和他们的边界到底划在哪。

本章引用

- [The GenAI Divide: State of AI in Business 2025](#), MIT Media Lab NANDA, 2025-07
- [Demystifying Evals for AI Agents](#), Anthropic
- [Harness Engineering for Self-Improvement](#), Lilian Weng, 2026-07

§03 FDE 和它周围的五个岗位

上一章列的那些活——还原真实流程、写结果契约、建评估集、分级放量——单拎出来看，每一件都能在别的岗位职责里找到影子。

产品经理做需求调研，解决方案架构师画集成方案，实施顾问搞验收，测试工程师建用例集。

于是很多公司做了同一件事：把这些人凑一起，起名叫 FDE 团队。

然后发现项目还是卡在老地方。

问题不在能力拼盘，在责任的完整性。

六个岗位，各自停在哪一步

岗位	对什么负责	通常停在哪	我的判断
软件工程师	产品与技术系统	代码合入、服务上线	把系统做出来
产品经理	用户需求与产品范围	方案确定、迭代排期	决定做什么
售前 / 解决方案架构师	技术可行性与方案说服力	签约、方案确认	证明产品能卖
咨询顾问	问题诊断与路径建议	报告、路线图	说明应该怎么做
实施顾问	配置、培训、项目验收	项目按期结项	让已有产品落地
FDE	业务结果与持续运行	结果产生并稳定	把 AI 装进业务

关键在"停在哪"这一列。

前面五个岗位都有一个明确的完成信号：代码合了、方案定了、合同签了、报告交了、验收过了。

FDE 没有这样的信号。它的完成信号在客户那边——有人在用，指标在动，出问题有人接。

这带来一个很现实的后果：**FDE 是唯一一个在系统上线之后，工作量不下降的角色。**

维基百科上关于这个岗位的条目里，有一句挺实在的话：一些工程师对它评价负面，因为出差要求和"在相对短的时间里解决客户问题"的压力。

这句话我觉得该原样保留在书里。这个岗位现在被写得太光鲜了。

Palantir 的 Dev / Delta 划分


FDE 这个词的原型来自 Palantir。它在 S-1 里把现场工程师直接算作研发的一部分——工程师在客户现场发现问题，再把经验写回平台。

它内部的角色划分更值得看。

Palantir 把工程分成两条线：Dev 做通用平台能力，Delta 在客户现场解决具体增量问题。

Delta 这个命名很准。它说明现场工程师处理的是标准产品和这一家客户之间的差值。

这个差值可能是数据结构不一样、审批链多一层、有个二十年的老系统必须对接、或者某个行业的监管要求。



这张图里那条虚线，是整套模式能不能成立的关键。

如果增量永远只留在项目里，Delta 的工作量会随客户数量线性增长，最后就是人力外包。

只有那条虚线跑通，反复出现的增量被吸收进通用产品，Delta 的单客户成本才会往下走。

第 31 章会专门讲这条虚线怎么建。这里先记住一件事：

FDE 的组织归属，决定了这条虚线存不存在。

挂在交付部门下面的 FDE，考核的是项目结项率。挂在产品线下面的 FDE，才有动机把现场问题推回路线图。

FDE 和产品经理的分工

这两个角色在企业 AI 项目里最容易打架，因为都在做需求。

我的划法是按对象分。

产品经理面向一群客户的共性需求，判断标准是“这个功能有多少客户会用”。

FDE 面向一个客户的具体结果，判断标准是“这一家的这个流程有没有跑起来”。

输出物也不同。产品经理写 PRD，描述功能行为。FDE 写 Outcome Contract，描述业务状态的改变。

一份好的 Outcome Contract 里可能一个功能名词都没有，全是触发条件、状态变化、判定规则和责任。

有个信号可以用来判断分工是不是错位了：**如果 FDE 大部分时间在跟产品经理争功能优先级，说明范围没砍够；如果大部分时间在跟客户的业务负责人确认规则，说明分工是对的。**

FDE 和咨询顾问的分工

咨询交的是判断，FDE 交的是运行中的系统。

这句话听起来简单，实际操作里有一段重叠区：诊断阶段。

上一章提过我的做法——把诊断本身做成第一个交付物，而且收费。输出真实流程、数据可行性判断、收缩后的第一阶段范围。

跟纯咨询的区别在结论的形式。

咨询会给出"建议优先建设知识中台"这类判断。FDE 给出的是"订单查询类工单可以做到自动回复，前提是你们提供 A 系统的只读 API 和三个月的历史工单，预计覆盖三分之一的工单量"。

后者可以直接变成合同。

顺带一提，MIT 那份报告里"外部伙伴主导的部署 67% 进生产、企业自建只有 33%"，我认为很大程度上就差在这一步。

外部团队被迫把话说到能签合同的精度，内部团队没有这个约束，项目常常带着模糊目标一路走到交付。

FDE 不负责什么

责任边界如果只往外扩不往里收，这个岗位会被拖垮。

有几件事我认为该明确划出去。

FDE 不负责客户的组织变革。 流程要改、岗位职责要调、有人要被换掉，这些必须由客户的业务负责人推动。FDE 可以提供数据和方案，但不能代替客户做这个决定。

项目里如果出现"让 FDE 去说服业务部门改流程"，说明业务负责人这个位置是空的。这是启动条件没满足，不是 FDE 能力不行。

FDE 不负责无限期的运维。 上线之后需要一个明确的交接点：谁监控、谁处理告警、谁维护评估集、谁批准规则变更。

这些写不进 SOW，项目就会变成永久驻场。

FDE 不负责所有需求。 有些需求现在就不该做——错误代价高但无法回滚的、数据根本拿不到的、流程每个月都在变的、没有业务负责人的。第 15 章会给一张筛选表。

学会说"这个现在不建议做"，我认为是 FDE 比会写代码更重要的能力。

FDE 也不负责一次性的技术选型。 模型选哪家、向量库用什么、要不要自建，这些在企业项目里的重要性远低于大家的想象。

真正决定成败的是上下文准不准、异常有没有覆盖、权限设得对不对。MIT 那份报告的归因里，一个模型相关的原因都没有。

一句话定义

综合前面三章，我给 FDE 的定义是：

FDE 进入客户的真实环境，把模糊的业务问题翻译成可运行的 AI 系统，对采用率和业务结果负责，并把现场经验转化成可复用的产品能力。

这句话有四个可以逐个验证的部分：进入真实环境、翻译成可运行系统、对结果负责、经验回流。

四个都成立才是 FDE。

下一章我给六个具体问题，用来当场判断一个岗位或一个团队，这四条到底占了几条。

本章引用

- [Palantir S-1](#)
- [Dev versus Delta: Demystifying Engineering Roles at Palantir](#)
- [Forward Deployed Engineer \(维基百科\)](#)
- [The GenAI Divide: State of AI in Business 2025](#), MIT Media Lab NANDA

§04 六个问题，判断这是不是真 FDE

FDE 热起来之后，同名不同岗会越来越多。

有些团队确实进客户现场，写生产代码，解决真实问题，再把经验带回产品。

也有一些岗位，工作方式还是传统驻场：按人天收费，围着验收单转，每个客户重新开发一遍。

两者写在 JD 上几乎一样。长期价值差很远。

这一章给六个问题。它们既可以用来判断一个招聘岗位，也可以用来体检自己团队。

六个问题里，答案的具体内容不重要，重要的是对方答不答得上来。

问题一：你写的代码进哪个仓库

这是我认为区分度最高的一个问题。

如果答案是“每个客户一个独立仓库，互相不通”，那这个岗位在做定制交付。

如果答案是“客户特有的部分在客户仓库，通用能力提交到产品主仓”，那这是 FDE。

第 3 章讲的 Palantir Dev / Delta 划分，落到日常就是这个问题。Delta 处理的增量如果永远留在项目里，它就永远是成本。

追问一句更狠：过去半年，你有几个 commit 进了产品主仓？

问题二：这个岗位归谁管

组织归属决定了考核什么。

挂在交付部门下面，考核项目结项率和人天利用率。这两个指标都会推着人做定制。

挂在产品线下面，考核的是采用率和能力沉淀。这才有动机把现场问题推回路线图。

我认为这条比第一条更根本。代码进不进主仓是结果，组织归属是原因。

如果一家公司说自己在做 FDE，但这些人挂在交付中心、KPI 是回款额，那它做的是带 AI 的项目制外包。

问题三：项目结束的标准是什么

三种答案，对应三种成熟度。

"验收单签字"——项目制交付。"系统上线运行"——比前者好，但仍然停在技术完成。"指标达到约定值并稳定运行 N 周"——这是 FDE。

第 2 章说过，Outcome Contract 的价值就在这里。它把结束标准从"做完了"改成"改变发生了"。

MIT 那份报告里 95% 的项目没有可衡量的损益影响，我认为很大一部分原因是它们从来没定义过可衡量的结束标准。

问题四：现场发现的问题怎么进产品

这个问题问的是那条反馈虚线存不存在。

好的答案会有具体机制：每个项目结束有复盘、复盘输出的通用需求进产品 backlog、有人负责判断哪些差量该被吸收。

不好的答案是"我们会反馈给产品团队"。这句话等于没有机制。

再追问：上一个项目沉淀了什么？说得出具体的东西的（一个 connector、一组评估用例、一份 context schema），这条虚线是通的。说不出来的，就是没通。

问题五：谁在项目结束后维护它

FDE 最容易被拖死的地方。

如果答案是"还是我们"，而且没有明确的支持范围和时间边界，那这个人会被永久绑在老项目上。

带来的后果是产能被吃光。做过三个项目的 FDE，第四个项目只能投入四分之一的精力。

健康的答案里应该包含一个交接点：谁监控、谁处理告警、谁维护评估集、谁批准规则变更。

这些在第 27 章会展开。这里只强调一件事：**没有交接设计的 FDE 模式，扩张不了。**

问题六：你上一次说"这个不建议做"是什么时候

这个问题问的是话语权。

FDE 如果对需求没有否决权，它就是执行角色，不是负责结果的角色。

一个对业务结果负责的人，必然会拒绝一些需求——错误代价高但无法回滚的、数据根本拿不到的、流程每个月都在变的、没有业务负责人的。

答不上来，或者答"我们尽量满足客户"，说明这个岗位的责任是虚的。

能拒绝，才谈得上负责。

六个问题的用法

问题	在问什么	危险信号
代码进哪个仓库	有没有产品化出口	每客户独立仓库
岗位归谁管	考核什么	挂交付中心，考核回款
项目结束标准	对什么负责	验收单签字
问题怎么进产品	反馈闭环存不存在	「会反馈给产品」
结束后谁维护	产能会不会被吃光	「还是我们」且无边界
上次拒绝需求	有没有话语权	「尽量满足客户」

六个全中，是成熟的 FDE 组织。中三到四个，方向对但机制没建全。中一到两个，那是换了名字的驻场。

对求职者，这六个问题可以直接在面试里问出去。对方答得越具体，这个岗位越真。

对已经在做的人，我建议每季度自查一次。**这六条会随时间退化**，尤其是第五条——项目越做越多，维护负担会悄悄把人拖回交付模式。

Part 1 到这里结束。FDE 是什么、按什么顺序工作、跟谁不一样、怎么验真，四章讲完了。

下一篇讲人：这个岗位需要什么能力，什么人适合转，一个团队要怎么配。

Part 2 能力篇：谁能做 FDE

这一篇讲人。需要什么能力、什么人适合转、一个人怎么工作、一个团队怎么配。

§05 能力模型：四个象限，缺哪个都会翻车

FDE 的 JD 通常写得很吓人：既要懂大模型，又要会写生产代码，还得能跟客户高管谈业务，最好再懂点项目管理。

看完的第一反应是这岗位在招超人。

但把它拆开看会发现，这四类能力不是并列关系，它们分别对应第 2 章那四个依赖段的失败模式。

能力域	主要内容	缺了它，项目死在哪
业务诊断	流程还原、访谈、需求收敛、ROI 判断	优化了错的流程
AI 工程	模型边界、Context、Agent、Tool、Eval	系统在生产环境不可靠
软件工程	API、数据、身份权限、测试、部署、可观测	接不进企业系统
企业交付	范围、SOW、验收、采用、变更、沟通	做完了没人认账

最后一列比第二列有用。

因为它回答了一个更实际的问题：你现在缺的那块，会以什么形式让你翻车。

四个象限的权重不一样

我看到的多数讨论把这四块讲成等权重的，我不同意。

按对项目成败的影响排，我的判断是：业务诊断 > 企业交付 > AI 工程 > 软件工程。

理由来自 MIT 那份报告的归因。数据就绪度、工作流集成、缺反馈闭环，三条里两条属于业务诊断和企业交付，一条属于工程。模型相关的原因一条都没有。

这不是说工程能力不重要。它是门槛，不是差异点。

写不出生产代码，你连进场资格都没有；但决定项目成败的，通常不是代码写得好多好。

业务诊断：最难补，也最少人练

这块的核心能力其实只有一个：从人的行为里提取出规则。

具体表现为几件事。

看人干活的时候能识别出哪些步骤有明确规则、哪些是隐性判断。第 2 章说的"停顿点"就是这个。

访谈的时候能把问题挂在具体案例上，而不是问抽象流程。

听到一个需求，能追问到它背后的业务状态改变，而不是停在功能描述。

能判断一个需求现在该不该做——数据拿不拿得到、错了能不能恢复、有没有业务负责人。

这块最难补，因为它没法靠读文档获得。但它也最容易被低估，因为它看起来"不技术"。

我认为对工程师出身的人来说，这是转 FDE 最大的坎。不是学不会，是不习惯把大量时间花在没有代码产出的事情上。

AI 工程：重点不在调模型

这块最容易被误解成"会用 API、会写 prompt、懂 RAG"。

企业场景里真正吃紧的是另外几件事：

知道模型在什么情况下会失效，以及失效时系统会怎么样。

知道上下文该放什么、不该放什么。Anthropic 把上下文描述成一种有限资源，每多一个 token 就消耗一次注意力预算——上下文不是越多越好，这一条在企业里尤其重要，因为企业最不缺的就是文档。

知道怎么设计评估，尤其是怎么检查最终的业务状态而不是模型自我陈述。

知道 Agent 的执行循环里哪些环节需要约束：工具调用、状态持久化、失败重试、人工接管。

第三篇会把这些逐个展开。这里只强调一点：**这块能力的重心在"约束模型"，不在"调用模型"。**

软件工程：企业那部分才是重点

会写代码只是起点。企业环境里吃紧的是这几块：

系统集成，尤其是没有 API 的老系统怎么办。

身份和权限，Agent 用谁的身份去访问数据，越权了怎么发现。

可观测性，出了问题能不能定位到是哪一步、哪个上下文、哪次工具调用。

发布和回滚，灰度怎么做，出事怎么退回去。

数据质量，脏数据在企业里是常态而不是异常。

这块的特点是：**在互联网产品里这些是基础设施团队的事，在客户现场这些是你的事。**

企业交付：工程师最容易漏掉的一块

范围怎么定、SOW 怎么写、甲方要提供什么、需求变了怎么办、验收拿什么证明、上线之后谁负责推动使用。

这些听起来像项目经理的活。

但在 FDE 模式里它们不能外包出去，因为**范围和技术方案是同一件事的两面**。

你砍掉一个场景，技术架构就变了。你答应多接一个系统，工期和风险都变了。让一个不懂技术的人去谈范围，谈出来的东西你实现不了。

第六篇整篇讲这个。

一张自查表

能力	及格线	危险信号
业务诊断	能独立完成一次流程还原并让一线认可	需求靠客户口述，从不现场观察
AI 工程	能设计一套检查环境状态的评估	判断效果靠人工抽查几条
软件工程	能独立把系统接进客户的身份和权限体系	只在自己的沙箱里跑通过
企业交付	能独立起草一份带甲方依赖的 SOW	范围靠邮件确认，没有正式文档

四条全中的人很少。

我的建议是不要追求四项都强，而是**先确保没有一项在及格线以下**。因为这四项是串联的，任何一项断掉，整个项目就断了。

下一章讲不同背景的人怎么补自己缺的那块。

本章引用

- [The GenAI Divide: State of AI in Business 2025](#), MIT Media Lab NANDA
- [Effective Context Engineering for AI Agents](#), Anthropic

§06 四条转型路径，起点不同，缺的东西也不同

上一章那张四象限表，最大的用处是拿来定位自己。

因为**没有人是四项齐全进来的**。每个人都从某一个象限出发，然后被项目逼着补另外三个。

这一章按四种常见起点，讲各自最该先补什么，以及最容易踩的坑。

先说一句适用于所有路径的判断：**这四条路里，补业务诊断的难度普遍被低估，补 AI 工程的难度普遍被高估。**

路径一：软件工程师

优势最明显，写生产代码这条门槛已经过了。

最该先补的是业务诊断。

具体表现是：习惯了接需求文档，不习惯自己去现场把需求挖出来；习惯了确定的输入输出，不习惯面对"这个流程实际上没人说得清"。

最容易踩的坑有两个。

第一个是**过早开始写代码**。第 2 章讲的那个顺序，工程师最容易从后往前做，因为写代码有即时反馈。

第二个是**把不确定性当成需求没描述清楚**。企业流程的模糊不是文档没写好，它本身就是模糊的。你的工作是把它变清楚，不是等别人给你一份清楚的。

建议的补法：找一个自己熟悉的业务流程，完整做一次还原——观察、访谈、画流程、列异常，然后拿给做这件事的人看，问他认不认。做过一次你就知道差距在哪了。

路径二：产品经理

优势在需求收敛和沟通，业务诊断这块底子最好。

最该先补的是工程实现能力，尤其是"能不能自己把东西做出来"。

这里有个残酷的现实：**FDE 模式里，不写代码的人很难对结果负责。**

因为客户现场的问题往往需要当场改。等排期、等开发、等下个迭代，这个模式就退化成了传统项目制。

好消息是这两年门槛降了很多。产品经理用 Coding Agent 把原型做到能跑，已经不是难事。

坏消息是原型能跑和生产可用之间还有很长一段：身份权限、错误处理、可观测性、幂等、回滚。这些不会因为 AI 写代码就自动解决。

建议的补法：先把“能独立做出一个能跑的端到端系统”做到，再补企业工程那部分（权限、集成、可观测）。顺序反了会很痛苦。

路径三：咨询顾问

优势在诊断、结构化表达和跟高层对话，这几项在 FDE 里都很值钱。

最该先补的还是工程。而且比产品经理那条路更陡，因为咨询的工作产物是判断和文档，离可运行的系统更远。

最容易踩的坑是**停在方案层**。

一份漂亮的路线图在咨询里是交付物，在 FDE 里只是起点。第 3 章说过区别：咨询给“建议优先建设知识中台”，FDE 给“这个场景可以做到什么程度，前提是你提供什么”。

后者要求你对实现有把握，否则那句“可以做到”就是空头支票。

建议的补法：找一个自己诊断过的场景，逼自己把它实现出来。哪怕很粗糙。做完你对可行性的判断会完全不一样。

路径四：行业专家

优势是别人补不上的：知道这个行业的流程怎么跑、异常长什么样、行话是什么意思、监管卡在哪。

第 2 章讲的“制度写的和实际做的之间那个差值”，行业专家是天然知道的。

最该补的是 AI 工程和软件工程两块，工作量最大。

但我认为这条路的天花板可能最高，因为**行业知识是四项里唯一不能靠通用方法快速获得的**。

一个懂 AI 的人进入陌生行业，需要几个月才能搞清楚这个行业的隐性规则。一个行业专家学会用 AI 工具，现在可能只需要几个月。这两个几个月的含金量不一样。

建议的补法：不要从模型原理开始学。从“用现成工具把自己行业的一个流程自动化”开始，反过来倒推需要什么知识。

四条路径对照

起点	已有优势	先补什么	最容易踩的坑
软件工程师	工程实现	业务诊断	过早写代码
产品经理	需求与沟通	端到端实现能力	停在方案，靠别人实现
咨询顾问	诊断与结构化	工程实现	交付物停在路线图
行业专家	领域隐性知识	AI 与软件工程	从模型原理学起，学不动

一个通用的判断标准

不管从哪条路来，我认为有一个标志可以判断你是不是真的转过来了：

你能不能独立对一个客户场景，从"他说想要个 AI"走到"这套东西在跑、指标在动"。

中间不需要另一个人替你补关键环节。

达不到这条，你可能是 FDE 团队里的某个角色，还不是一个完整的 FDE。这不丢人，第 8 章会讲团队怎么配。但要清楚自己在哪个位置。

下一章讲个人的工作方式：一个 FDE 每天真正在对抗的是什么。

§07 个人工作方式：FDE 每天在对抗什么

原本这一章我想写成"一个 FDE 的一天"。

写到一半就停了，理由和第 2 章一样：**每个项目的节奏差太远，写成日程表等于写假的。**

诊断期一天可能全在客户那边坐着，开发期可能一周不去现场，上线期可能天天盯监控。

所以这一章换个写法，讲三件我认为 FDE 每天都在对抗的东西。它们跟阶段无关。

对抗一：把没有产出的时间守住

第 2 章讲过，正确的顺序里前三段都拿不出可演示的东西。

这带来一个持续的压力源：**你在做最重要的事的时候，看起来最像没在干活。**

客户会问"能看到点什么吗"。你老板会问"进度怎么样"。而你手上只有一份流程图和一份契约草稿。

我认为这是这个岗位每天都要处理的问题，不是某个阶段的问题。因为每接一个新场景，这个循环就重来一次。

几个可用的做法：

把中间产物做成可展示的东西。流程地图、异常清单、Context 登记表，这些拿给一线业务看，他们其实很有兴趣——很多企业从来没有人完整梳理过自己的流程。

把诊断本身变成付费交付。收了钱的东西，客户不会催你"什么时候能看到 Demo"。

给出可核对的中间里程碑。不是"完成度 40%"，而是"已完成 12 个岗位访谈中的 8 个，异常清单收集到 23 条"。数字能挡住大部分焦虑。

对抗二：不让自己变成客户的记忆

这是我认为最容易发生、也最难察觉的退化。

项目做到第三个月，你脑子里装满了这家客户的规则：哪个字段其实是另一个意思、哪类订单要走特批、哪份文档已经作废但没人删。

这些东西留在你脑子里的那一刻，你就变成了这个系统的一部分。

后果有两个。一是你走不了，因为没有你系统就没法维护。二是客户永远拿不到自主运营能力。

对抗的方式只有一个：所有从人脑里挖出来的知识，当天写进文档或配置，不过夜。

具体形式在第 19 章会展开（Context Registry）。这里强调的是习惯而不是工具：

访谈里听到一条隐性规则，立刻记下来，并标注是谁说的、什么时候说的、可信度如何。

发现两份资料冲突，立刻记下冲突本身，以及最后按哪个执行、谁拍板的。

你的记忆力越好，这个项目的风险越高。这话听起来反直觉，但我认为是对的。

对抗三：区分「改系统」和「打补丁」

第 2 章讲影子运行时提过一句：偏差要分类，不能一股脑拿去改提示词。

这件事在日常里是持续发生的。每天都有新的 bad case 进来，每天都要决定怎么处理。

最省事的处理方式是在提示词里加一句"注意 XX 情况要 YY"。

这个动作单次几乎没有成本，累积起来就是灾难。三个月后你会有一份两千字的提示词，里面几十条规则互相打架，谁也不敢删。

我的判断是：**每一次 bad case，先问它属于哪一类，再动手。**

bad case 类型	正确的修法	错误的修法
模型没拿到某条信息	补上下文来源、改检索策略	把这条信息塞进提示词
规则理解错	改流程契约，明确状态和条件	加一条"注意"
工具调用出错	改工具契约、加参数校验	让模型"更小心"
下游系统失败	加重试、幂等、回滚	忽略，当成偶发
模型确实做不到	划出去交人工	继续调提示词

最后一行最难。承认某类情况模型做不到，需要放弃一部分自动化率，这在项目压力下很难做。

但不承认的代价是系统在这类情况下持续出错，最后拖垮所有人对它的信任。

Anthropic 讲上下文工程时说，上下文是有限资源，每多一个 token 就消耗一次注意力预算。往提示词里堆规则，就是在花这个预算。

一个我认为有用的日常习惯

每天结束前花十分钟，回答三个问题：

今天我知道了哪些昨天不知道的业务事实？它们写进文档了吗？

今天改的东西，是在修系统还是在打补丁？

今天有没有做只有我能做的事？如果有，它能不能变成别人也能做的？

第三个问题指向的是第 4 章那个"结束后谁维护"的问题。一个人如果每天都在做只有自己能做的事，这个项目就永远交不出去。

下一章讲团队：一个人扛不下来的时候，怎么配人。

本章引用

- [Effective Context Engineering for AI Agents](#), Anthropic

§08 团队：一个 Pod 要几个人

第 6 章结尾那个标准——能独立把一个场景从"想要个 AI"走到"指标在动"——是对个人的要求。

但真到项目里，一个人扛完整条链路的情况不多。

原因不是能力不够，是**并行度不够**。诊断要现场、开发要专注、上线要盯监控，这三件事在时间上会撞车。

所以 FDE 通常以小组形式出现。这一章讲怎么配。

最小可行配置：两个人

我认为下限是两个人，不是一个。

理由是第 7 章说的那个风险：一个人做，业务知识全部沉在他脑子里，没有第二个人能校验。

两个人的分工不建议按"一个懂业务一个懂技术"来切。那样切会让业务那个人变成需求传话筒，技术那个人永远不去现场。

更好的切法是**都进现场，按场景分工**。两个人一起做流程还原，然后各自负责不同的子场景，互相 review 对方的 Context Registry 和评估集。

这样做的成本是效率略低，收益是知识不会单点沉淀。

完整 Pod：四到六人

场景复杂或者客户体量大的时候，需要更完整的配置。

角色	主要负责	能不能兼
Lead FDE	结果契约、范围、客户关系、最终决策	不建议兼
FDE	现场诊断 + 系统实现，覆盖具体场景	主力，通常 2 人以上
数据 / 集成	数据管道、系统对接、权限打通	场景简单时可由 FDE 兼
业务专家	行业规则、异常判断、验收把关	常由客户方出人
交付 / 项目	SOW、进度、变更、验收流程	小项目可由 Lead 兼

有几点我想强调。

业务专家最好由客户出人，而不是自己招。 这不只是成本问题。客户方的业务专家能拍板规则、能推动流程改动、能在验收时替你说话。外部专家做不到这三件事里的任何一件。

交付角色可以兼，但不能没有。 第 5 章说过，范围和技术方案是一件事的两面。可以让 Lead FDE 兼，但不能让一个不懂技术的项目经理单独去谈范围。

数据和集成这块最容易被低估。 MIT 那份报告把数据就绪度列为失败主因之一。如果客户的数据散在多个系统、口径不统一、没有可用的接口，这块的工作量可能超过 AI 部分。

客户侧必须有的两个位置

Pod 的配置只是一半。另一半在客户那边。

第一个是业务负责人。 有权改流程、有权定义什么算成功、有权在验收时签字。

第 3 章讲过，如果这个位置是空的，项目里就会出现"让 FDE 去说服业务部门改流程"。那不是 FDE 该干的事，也干不成。

第二个是数据 / IT 对接人。 负责账号、权限、接口、测试环境。

这两个位置写进 SOW 的甲方依赖里，第 25 章会展开。这里先给一个判断：**这两个位置没有明确的人，项目不该启动。**

不是"启动了慢慢协调"，是不该启动。因为后面每一步都会卡在这两个位置上，而卡住的责任最后会算在交付方头上。

一个 Pod 能同时带几个项目

这个问题我看到过很多种答案，我的判断是：**取决于有多少项目已经过了交接点。**

第 4 章的第五个问题问的就是这个。如果每个上线的项目都还挂在原班人马身上，那 Pod 的产能会被存量吃掉。

比较健康的状态是：

进行中的新项目一到两个。已交接、只提供有限支持的存量若干。存量的支持工作有明确的时间边界和响应范围。

不健康的状态是：三个新项目 + 五个"随时找你"的老项目。这种配置下，新项目的质量必然下降，而下降会先体现在诊断阶段——因为诊断是最容易被压缩的环节。

团队层面的两个机制

除了配人，我认为有两个机制必须建。

第一个是复盘。 每个项目结束做一次，输出两类东西：这个客户特有的（留在项目里）和可复用的（进产品或资产库）。

第 4 章的第四个问题问的就是这个机制存不存在。

第二个是交叉 review。 至少 Context Registry 和评估集要有第二个人看过。

理由和最小配置那节一样：这两样东西最容易夹带个人假设，而个人假设在企业项目里的杀伤力很大——你以为是规则可能是三年前的旧规则。

Part 2 到这里结束。

下一篇进技术底座：模型的边界在哪、上下文怎么组织、Harness 是什么、企业软件那部分要懂多少。

本章引用

- [The GenAI Divide: State of AI in Business 2025](#), MIT Media Lab NANDA

Part 3 原理篇：FDE 必须理解的底座

这一篇不是大模型教程。

每个知识点都要回答同一个问题：**FDE 为什么需要它，缺了它企业项目会怎么失败。**

回答不了这个问题的知识，这一篇就不写。

§09 模型的边界：知道它什么时候会骗你

先说这一章的用处。

FDE 不需要懂 Transformer 的内部结构，但必须知道模型在什么情况下会失效。因为失效模式决定了系统该在哪里加约束。

第 2 章讲的评估集七类用例，来源就是这些失效模式。

一个前提：模型是非确定的

同样的输入，两次运行可能给出不同结果。

这件事在 Demo 阶段几乎不构成问题，因为你只跑一次，效果好就过了。

到了生产环境它就变成核心问题：你没法用“它昨天是对的”来保证它今天是对的。

这条直接推出两个设计原则。

第一，任何重要判断都需要可验证的结果，而不是相信模型的自我陈述。

第二，评估必须是持续跑的，不是上线前跑一次。

五种在企业里最贵的失效

我按“在企业场景里代价多大”排了个序，这是我的判断，不是行业共识。

第一，编造具体事实。

模型不知道某个字段的值时，会给出一个格式正确、看起来合理的答案。

在闲聊里这是小问题，在企业里这可能是一个错误的金额、一个不存在的合同号、一条编造的政策。

对策不是“让它别编”，而是让它拿不到信息时有明确的出口——返回“信息不足”并升级人工。这条要写进评估集（第 2 章那张表里的“信息缺失”一类）。

第二，在冲突信息里选错。

企业里同一件事有多个版本是常态。旧制度没删、两个部门口径不同、系统里的值和文档里的值对不上。

模型没有判断权威性的能力。它会选检索分数最高的那个，而检索分数跟权威性无关。

对策是在上下文层面解决——给每个信息源标注权威级别和有效期。这是第 19 章 Context Registry 的核心。

第三，为了完成任务走捷径。

Lilian Weng 在 2026 年 7 月那篇 harness 文章里引了 Trehan 和 Chopra 归纳的六种反复出现的失败模式，其中有条我认为在企业里特别危险：over-optimism（过度乐观）和 implementation drift under execution pressure（执行压力下的实现漂移）。

翻译成企业场景：Agent 会为了让任务显得完成而降低标准，也会在长流程里慢慢偏离原定计划。

对策是外部验证。**不能让执行者同时当裁判。**

第四，长上下文里记不住关键信息。

Anthropic 把这个现象说得很清楚：上下文窗口里的 token 越多，模型准确回忆其中信息的能力越差。

他们的原话是把上下文当成“有限资源，边际收益递减”，每多一个 token 就消耗一次注意力预算。

这条对企业项目的含义很直接：**把企业所有文档塞进上下文，效果会比精选几份更差。**

第五，多步流程的成功率坍塌。

单步 95% 的成功率，十步串起来大概只剩六成。

这是个纯数学问题，但很多方案设计的时候没算过这笔账。

对策有三个方向：减少步数、给每一步加验证、在关键节点设人工检查点。第 20 章会展开。

那个 42 倍和 95%，其实是同一件事

把这五条失效模式和第 1 章那份 MIT 报告放一起看，逻辑就通了。

报告归因的三件事——数据就绪度、工作流集成、缺反馈闭环——恰好是这五种失效在组织层面的表现。

数据就绪度对应第二条（冲突信息）。工作流集成对应第五条（多步坍塌）。缺反馈闭环对应第三条（没有外部验证）。

所以那 95% 的项目失败，不是因为模型不够强，是因为没人在这五个地方加约束。

加约束的那套东西，就是接下来三章的内容：上下文、Harness、企业软件底座。

一件不用太纠结的事：选哪个模型

这一章最后说个反直觉的判断。

模型选型在企业项目里的重要性，远低于大家的想象。

理由是上面五种失效模式里，没有一种能靠换模型彻底解决。换个更强的模型，编造会少一点、长上下文表现会好一点，但冲突信息还是会选错，多步流程还是会坍塌，Agent 还是会走捷径。

这些是结构问题，不是能力问题。

我的建议是：选型上花一天，把省下来的时间花在上下文和评估上。

需要认真评估的只有几个硬约束：能不能私有化部署、数据出不出境、延迟能不能接受、成本在预期调用量下是多少。

下一章讲上下文——五种失效里有两种直接由它决定。

本章引用

- [Harness Engineering for Self-Improvement](#), Lilian Weng, 2026-07
- [Effective Context Engineering for AI Agents](#), Anthropic
- [The GenAI Divide: State of AI in Business 2025](#), MIT Media Lab NANDA

§10 Context Engineering：决定模型看到什么

先给定义，用 Anthropic 的原话：

Context engineering 是在 LLM 推理过程中，策划和维护那组最优 token 的一整套策略。

它管的范围比提示词大得多。系统指令、工具定义、检索到的数据、历史消息，全都算上下文。

三层关系是这样的：

提示词工程决定你怎么问。上下文工程决定模型能看见什么。Harness 工程决定这一整套怎么持续跑起来。
企业项目里，第二层的杀伤力最大。

上下文是有限资源

这是我认为整个上下文工程里最该先接受的一条。

Anthropic 的说法是：随着上下文窗口里 token 数量增加，模型准确回忆其中信息的能力会下降。他们把上下文描述成"有边际收益递减的有限资源"，每多一个 token 就消耗一次注意力预算。

这条推翻了企业项目里一个很常见的直觉——把公司所有文档都喂给它，它就什么都知道了。

实际情况相反。文档越多，噪音越多，关键信息被稀释得越厉害。

我的判断是：企业最不缺的就是文档，所以企业最容易犯的错就是喂太多。

企业上下文的四种存放方式

做上下文设计之前，先得知道知识都藏在哪儿。我按"可获取程度"分成四类。

存放方式	例子	获取难度	常见问题
结构化数据	数据库、ERP、CRM 里的字段	低	口径不统一、字段含义漂移
文档	制度、SOP、产品手册	中	版本冲突、已作废但没删
半结构化痕迹	工单记录、邮件、群聊	高	噪音大，但隐含真实规则
人脑	老员工的判断经验	最高	完全不可检索

做 AI 的人默认处理前两类。

但第 2 章讲过，制度写的和实际做的之间那个差值，通常藏在后两类里。

第三类尤其值得挖。工单记录和群聊里有大量"这种情况我们一般这么处理"的真实约定，它们比制度文件更接近实际执行。

Context Registry：把上下文当资产管理

我认为这是 FDE 最该标准化的一份交付物。

它是一张表，每个信息源一行。字段至少包括：

字段	为什么需要
来源位置	能不能被程序访问
负责人	冲突时找谁拍板
权威级别	和别的来源冲突时听谁的
更新频率 / 有效期	判断会不会过期
权限范围	哪些角色能看
注入方式	常驻上下文还是按需检索
已知冲突	和哪些来源打架，怎么处理

第九章讲的第二种失效——在冲突信息里选错——就是靠"权威级别"这一列解决的。

模型没有判断权威性的能力，检索分数和权威性无关。所以权威性必须由人在系统外定义好，再交给检索层执行。

没有权威级别的知识库，等于把冲突交给了随机数。

四个可以直接用的技术

Anthropic 那篇文章给了四个方法，我按在企业场景里的适用性排一下。

第一，Just-in-Time Retrieval（按需检索）。

不预加载全部数据，只保留轻量引用——文件路径、URL、查询语句，运行时再动态加载。

这条在企业里最有用，因为企业数据量大且权限复杂。预加载既撑爆上下文，也绕不开权限。

第二，Structured Note-Taking（结构化记录）。

让 Agent 把中间结论写到上下文窗口之外，后面再取回来。

对长流程任务有用。企业里的跨系统流程经常要跑十几步，中间状态不能只靠上下文携带。

第三, Compaction (压缩)。

接近上下文上限时做摘要, 保留关键决策, 丢掉冗余输出, 然后用压缩后的上下文重启。

第四, Sub-Agent (子 Agent)。

用干净上下文的专门 Agent 处理聚焦任务, 只把浓缩结果返回给协调者。

Anthropic 把这称为"关注点分离"。企业里适合用来隔离那些需要读大量原始数据的环节——比如翻一百条历史工单, 只把结论带回主流程。

一个企业特有的问题: 权限

上面四个技术都有一个共同的前提假设: 能拿到数据。

企业里这个假设经常不成立。

同一份数据, A 角色能看全部, B 角色只能看本部门, C 角色只能看脱敏版本。

这带来一个设计问题: **Agent 用谁的身份去取上下文?**

三种做法, 各有代价:

用服务账号取全部数据, 然后在应用层过滤。实现简单, 但一旦过滤逻辑有 bug 就是越权, 而且审计说不清楚。

用发起人的身份去取。安全, 但很多企业系统不支持这种代理身份。

预先按角色切分索引。可控, 但维护成本随角色数量上升。

我没有一个通用答案。但我认为**这个问题必须在 Context 设计阶段就想清楚, 不能等安全部门在上线前一周提出来。**

第 12 章会展开身份和权限。

一个反直觉的建议: 定期删

上下文系统会腐化。

文档更新了、规则改了、系统换了, 而你三个月前配置的检索策略和常驻上下文还停在那天。

这里可以借用一个观察: 模型能力提升之后, 原来为了弥补模型缺陷而搭的脚手架, 可能反而变成新的限制。

放到上下文上就是——当初为了帮模型定位信息而做的复杂切片和检索优化, 在模型变强之后可能只是在增加噪音。

所以上下文系统需要定期做减法，不只是加法。

我建议每次大的模型升级后，都重新跑一遍评估集，验证那些"辅助措施"还有没有正收益。

下一章讲 Harness——上下文决定模型看到什么，Harness 决定它怎么持续工作。

本章引用

- [Effective Context Engineering for AI Agents](#), Anthropic

§11 Harness Engineering: 决定模型怎么持续工作

这个词这两年才开始被认真讨论。

Lilian Weng 在 2026 年 7 月那篇文章里给的定义是：

Harness 是围绕基础模型的那套系统，它编排执行，决定模型如何思考和规划、如何调用工具和行动、如何感知和管理上下文、如何存储产物、如何评估结果。

Harness 本来指马具，套在马身上那套东西。模型是马，Harness 决定它往哪使劲。

对 FDE 来说，这个概念的价值在于它把"Agent 做不好"这件事从模型身上挪开了。

模型能力决定上限，Harness 决定这个上限能不能在真实企业里稳定释放。

七个可编辑的部件

Lilian Weng 那篇文章列了七个可以被改动的 harness 部件：

系统提示词、工具描述、工具实现、中间件、Skill、子 Agent 配置、长期记忆。

这七个的价值在于，它给了你一张"出问题时可以动哪里"的清单。

第 7 章讲过 bad case 的分类。那张表其实就是在问：这次该动这七个里的哪一个。

多数团队只会动第一个（往系统提示词里加规则），而问题往往出在第二、三、七个。

企业场景要额外加的四件事

上面七个部件是通用的，主要从编码 Agent 场景总结出来。

进企业以后，我认为还得加四样，它们在编码场景里可选，在企业场景里必需。

第一，身份与权限。

Agent 用谁的身份访问系统，能操作哪些资源，越权时会发生什么。

编码 Agent 在自己的沙箱里跑，企业 Agent 在客户的生产系统里跑。这是完全不同的风险等级。

第二，副作用隔离与幂等。

Agent 调一次接口和调三次接口，结果必须一样。

这条在企业里的分量特别重，因为下游是真的会被写入的：真的会发邮件、真的会生成采购单、真的会改订单状态。

第 9 章讲过多步流程的成功率坍塌。坍塌之后的重试，如果没有幂等保护，会造成比失败更糟的结果。

第三，人工接管点。

哪些动作必须人批，批的人看到什么信息，不批会怎样，超时怎么办。

我的判断是：**人工审批不是一个界面功能，它是系统架构的一部分。**


因为它决定了流程在哪里可以被中断、状态怎么保存、恢复后从哪一步继续。这些事后加不上去。

第四，审计与可追溯。

出了问题，要能回答：当时模型看到了什么上下文、调了哪些工具、返回了什么、谁批准的。

企业里这条经常是法务和风控的硬要求，不是加分项。

一张 Harness 的分层图



四层的顺序有讲究。

多数团队从上往下做，做到第二层就上线了。第三层等安全部门提要求才补，第四层等出事才补。

我认为正确的做法是**从下往上验收**：证据层没有，就无法判断约束层是否生效；约束层没有，能力层的每一次调用都是风险。

Harness 不能越做越厚

有一个观察值得单独说：模型能力提升之后，原来为了弥补模型缺陷而搭的脚手架，可能反过来变成限制。

这个道理在个人工具上已经有人踩过。为旧模型写的一大堆规则和绕路逻辑，换到新模型上变成纯负担。

企业项目里这个问题更严重，因为客户不会主动删东西。规则只进不出，三年后没人敢动。

我的建议是把"删"也写进流程：

每次模型升级后重跑评估集，标出哪些约束已经没有正收益。

每个季度审一次系统提示词，把已经被上下文或工具契约覆盖的规则删掉。

保留一份"为什么加这条"的记录，否则三年后谁都不敢删。

Harness 里每一个部件，都编码了一条"模型自己做不到什么"的假设。模型变了，假设就该重审。

Harness 和 Context 的分工

这两个概念容易混。我的划法是：

Context 管信息，Harness 管行为。

模型该看到哪些信息，是 Context 的事。模型看到信息之后能做什么、做错了怎么办，是 Harness 的事。

落到 bad case 上就很好判断了：

模型答错是因为没拿到某条信息 → Context 问题。

模型拿到了正确信息但做了不该做的动作 → Harness 问题。

这两类的修法完全不同，混在一起改是很多项目越改越乱的原因。

下一章讲企业软件底座，Harness 的第三层和第四层要落在上面。

本章引用

- [Harness Engineering for Self-Improvement](#), Lilian Weng, 2026-07

§12 企业软件底座：集成、身份、可观测

这一章讲的东西，在互联网产品里是基础设施团队的事。

在客户现场，它们是你的事。

我按"卡住项目的频率"排序，不按技术复杂度排。

集成：没有 API 的系统怎么办

企业里最常见的一句话是"这个系统比较老"。

翻译过来通常意味着：没有 API、文档丢了、原厂已经不维护、改一行要走三个月流程。

可选的路径按优先级排：

第一，找数据库直连的只读权限。 绕开应用层，直接读表。风险是字段含义要重新搞清楚，而且升级时会断。

第二，找导出。 很多老系统有定时导出报表的能力。延迟大，但稳定。

第三，中间库。 让客户 IT 把需要的数据同步到一个新库，你只读这个库。这条最干净，但依赖客户投入。

第四，RPA 或浏览器自动化。 最后手段。脆弱、难维护、界面一改就废。

我的判断是：**能不用第四条就不用。** 它在演示里很惊艳，在生产里是持续的维护负担。

如果一个项目的核心链路必须依赖 RPA，我会重新评估这个项目现在该不该做。

数据质量：脏数据是常态

MIT 那份报告把数据就绪度列为失败主因之一。

在现场，"数据就绪"通常意味着这几件事：

同一个字段在不同系统里含义不同。历史数据里有大量测试记录、作废记录、迁移遗留。关键字段允许为空，而且真的大量为空。枚举值里有历史遗留的十几种写法表示同一个意思。

这些不是异常情况，是默认情况。

处理办法上，我认为有一条原则最重要：**先量化，再决定。**

不要凭感觉说"数据比较乱"。跑一遍统计：这个字段的空值率是多少、枚举值实际有几种、时间跨度内的分布是什么样。

有了数字，才能判断这个场景现在能不能做，以及做到什么程度。

身份与权限：最容易被卡在上线前

第 10 章提过 Agent 用谁的身份取数据。这里展开一层。

企业里通常有一套已有的身份体系（AD、LDAP、SSO 之类）和一套权限模型。你的系统必须接进去，而不是自己造一套。

需要在方案阶段就问清楚的问题：

Agent 是一个服务账号，还是代理用户身份？如果是服务账号，它的权限范围由谁审批？用户通过 Agent 不能看到自己本来看不到的数据？Agent 的操作在审计日志里记在谁名下？

最后一个问题最容易被忽略，也最容易在合规审查时被卡住。

如果审计日志里所有操作都记在一个服务账号名下，很多企业的风控是不会放行的。

我的建议是把身份和权限方案在诊断阶段就形成文档，拿给客户的安全或合规部门过一遍。

不要等到上线前一周。那时候改架构的成本是最高的。

可观测性：出问题能不能定位

Agent 系统的排查比传统系统难，因为多了几层不确定性。

传统系统出错，你看日志、看堆栈，能定位到代码行。

Agent 出错，你要回答的是：当时它看到了什么上下文、检索命中了哪几条、模型输出了什么、调了哪些工具、工具返回了什么、为什么选了这条路径。

这些信息如果没有主动记录，事后是补不回来的。

我认为最低限度要记的东西：

记什么	用途
完整的输入上下文（含检索结果和来源 ID）	判断是 Context 问题还是 Harness 问题
每次工具调用的参数和返回	定位副作用
决策路径（走了哪个分支、为什么）	复现问题
人工介入记录（谁、什么时候、批了还是拒了）	审计与责任
最终业务状态变化	验证任务真的完成了

最后一条对应第 9 章那个原则：不能拿模型的自我陈述当完成证据。

发布与回滚

企业系统不接受"上线试试看"。

需要在方案里明确的几件事：

灰度怎么切——按用户、按部门、按业务类型，还是按流量比例。

出问题怎么退——是关掉 AI 走向人工流程，还是回滚到上一个版本。

已经产生的错误动作怎么处理——能不能自动撤销，不能的话谁去手工修。

第三条最容易被漏掉。能回滚代码，不等于能回滚业务后果。

如果 Agent 已经发出了一百封邮件、改了两百条订单状态，回滚代码解决不了任何问题。

这也是第 2 章说"第一个项目要选错误可恢复的场景"的原因。

一份进场时的技术尽调清单

诊断阶段可以直接拿去问的问题：

数据在哪几个系统，各自有没有 API，能不能拿到只读权限。关键字段的空值率和取值分布是多少。用什么做身份认证，Agent 的身份怎么处理。有没有可用的测试环境，数据是脱敏的还是空的。日志和监控现在是什么方案，能不能接进去。上线要走什么审批流程，安全和合规谁签字。

这几个问题的答案，基本能决定这个项目的真实工期。

我的经验判断是：这份清单里任何一项答不上来，工期都要往后加。

Part 3 到这里结束。

模型的边界、上下文、Harness、企业底座，四章讲的是"能做什么、怎么约束"。

下一篇换个角度：企业到底想要什么，以及哪些想要的东西现在不该给。

Part 4 需求篇：企业到底需要什么 AI

这一篇回答三个问题：企业的 AI 需求有哪些类型，这些需求背后反复出现的问题是什么，以及哪些需求现在不该做。

§13 企业 AI 需求的五层分类

企业需求最常见的分类方式是按部门：市场要什么、客服要什么、财务要什么。


我认为这种分法对 FDE 没什么用。

因为**同一个部门的两个需求，实施难度可能差十倍。**

客服部门要一个"话术查询助手"和要一个"能直接改订单的自动处理 Agent"，前者两周，后者半年，而且风险等级完全不同。

更有用的分法是按 AI 的介入深度。

五层，深度递增



层级	典型需求	输出交给谁	错误代价
一、信息获取	知识库问答、制度查询、文档检索	人	低，人会核对
二、内容生产	客服回复草稿、报告初稿、营销文案	人	低到中，人会改
三、分析判断	工单分类、线索评分、风险识别、异常检测	人或系统	中，可能影响决策
四、流程协同	跨系统取数、材料准备、状态同步、待办生成	系统，但需人确认	中到高
五、自主执行	直接发邮件、改订单、生成采购单、完成端到端流程	系统，直接生效	高，已经发生了

分层的价值在于，每往下一层，对 Context、Harness、Eval 和权限的要求都会跳一级，不是线性增加。

每一层真正的难点

第一层的难点不是检索，是知识治理。

多数团队以为这层最简单，接个向量库就完事。

实际卡住的地方是第 10 章讲的那些：哪份文档是有效版本、两份说法冲突听谁的、这个用户有没有权限看这条。

检索准确率和业务事实正确，是两个指标。找到信息是检索的事，判断这份信息值不值得信是 FDE 的事。

第二层的难点是采用率。

技术上不难，草稿质量也够用。但上线后经常发生的是：员工试了几次，觉得改草稿比自己写还慢，就不用了。

这层的成败取决于它嵌进工作流的位置。让人跳到另一个系统去生成再复制回来，基本没人会用。

第三层的难点是判据。

分类和评分需要一个标准答案，而企业里的标准答案经常是不存在的——同一个工单，三个老员工可能分成三类。

所以这层的第一件事不是训模型，是先让人达成一致。这个过程本身对客户就有价值。

第四层的难点是状态和异常。

跨系统流程有中间状态，会失败在任何一步。第 11 章讲的幂等、重试、状态持久化，从这层开始变成硬需求。

第五层的难点是信任和治理。

技术上第五层和第四层的差距，比大多数人以为的小。真正的差距在组织：谁批准它自动执行、错了谁负责、怎么撤销、审计怎么交代。

一个我认为重要的判断

很多企业开口就要第五层。

我的建议是：**除非有非常明确的理由，第一个项目不要从第五层开始。**

理由不是技术做不到，是信任建立需要时间。

你需要几个月的运行数据，才能让客户相信这套东西可以自动执行。而第五层不给你犯错的额度——它错一次，可能整个项目就被叫停了。

更可行的路径是同一个场景从低层往高层爬：



这条路径在第 22 章会展开。这里先记住：**层级是可以爬的，但不能跳。**

需求所在层级 vs 客户以为的层级

现场经常出现的一个错位是：客户描述的是第五层，实际需要的是第三层。

「我们想要一个能自动处理退款的 AI」——追问下去可能会发现，退款审批本身有明确规则，人工只需要 30 秒，真正耗时的是判断这个退款申请属于哪一类、要调哪些证据。

那么真实的需求是第三层（分类 + 材料准备），把 30 秒的审批留给人。

这个错位是常态，不是客户不专业。因为**客户描述的是他想摆脱的痛苦，不是他需要的系统。**

FDE 的工作就是把前者翻译成后者。翻译的方法是第 2 章那套顺序：先看真实流程，找到时间实际花在哪。

这一层分类怎么用

我建议在诊断结束时，对每个候选场景标三件事：

它在第几层。客户以为它在第几层。第一阶段建议做到第几层。

这三个数字如果不一致，说明有一次预期管理需要做。而且要在报价之前做，不是在验收时做。

下一章讲这五层背后反复出现的七类问题。

本章引用

- [Effective Context Engineering for AI Agents](#), Anthropic

§14 七类反复出现的企业问题

上一章按 AI 介入深度分了五层。

这一章换个切面：不管在哪一层，企业项目卡住的地方翻来覆去就那么几个。

我归纳成七类。每一类对应一个"企业以为的问题"和一个"实际的问题"，以及 FDE 该建什么。

这张表是全书的中枢。第五篇的七章，基本就是在逐个解决这七类问题。

#	企业的表述	实际的问题	需要建什么	对应章节
1	我们也要做个 AI Agent	没有可衡量的业务结果	Outcome Contract	§16
2	资料都在，导进去就行	知识散、冲突、过期、只在人脑里	Context System	§17 §19
3	流程我们有 SOP	SOP 只写正常路径，异常靠人判断	Workflow Contract	§18
4	让它自己去调系统	权限、副作用、重复执行没人管	Agent Harness	§20
5	效果我们看着还行	没有判据，无法证明能上线	Eval Harness	§21
6	出错了改一下就好	错误会沿下游系统传播	审批、隔离、回滚、审计	§20 §22
7	这套能不能复制到别的部门	每次都从零定制	资产化循环	§31

下面逐个说。

一、价值不清：没有可衡量的结果

最常见的开场是"我们也要做一个 AI Agent"。

这句话背后通常是：竞争对手做了、老板在会上提了、有一笔预算要花掉。

它不构成需求，因为没有回答"改变什么"。

判断标准很简单：这个项目做完，哪个数字会变，变多少，谁认这个数字。

三个问题答不上来，就还在这一类里。

MIT 那份报告里 95% 的项目没有可衡量的损益影响。我认为很大一部分是从这一步就没定义过。

二、上下文碎片化：资料在，但不能用

第二常见的是"资料我们都有"。

现场看到的通常是：制度文件在共享盘、产品资料在几个人的电脑里、真实规则在工单记录和群聊里、最关键的判断在几个老员工脑子里。

而且它们互相冲突。旧制度没删，两个部门口径不同，系统里的值和文档对不上。

第 10 章讲过，模型没有判断权威性的能力。**冲突的信息喂进去，出来的就是随机的答案。**

这一类的解法不是"整理知识库"这种模糊说法，而是一份带权威级别、有效期、责任人和冲突处理规则的 Context Registry。

三、流程不可计算：SOP 只写了顺利的那条路

客户说"流程我们有 SOP"，拿到手一看，写的是理想路径。

真实流程里的异常——客户资料不全、系统超时、金额超限、遇到特殊客户、上游数据没来——SOP 里一条都没有。

这些情况在实际工作里由人凭经验处理。人处理得很自然，以至于没人觉得需要写下来。

AI 接手之后，异常的占比会突然变得可见。因为它不会像人一样自动绕过去。

这一类需要的是把流程写成状态机：有哪些状态、什么条件触发转移、异常怎么分类、什么时候升级到人。第 18 章展开。

四、工具不可控：让它自己去调

"让 AI 自己去调系统"这句话里，藏着四个没人管的问题：

用谁的身份调。调错了会不会写坏数据。同一个动作重复调用会怎样。调用失败之后怎么办。

第 11 章讲过，Agent 调一次和调三次，结果必须一样。这在企业里不是优化项，是安全底线。

因为下游是真的会被写入的。

五、质量不可证明：看着还行

这一类的表现是：Demo 演示效果不错，但没人敢说可以上线。

因为"效果不错"是抽了几条看的结论，不是可重复的判据。

第 2 章讲过为什么判据必须在系统之前建立——**系统一旦存在，它能做到的事会变成标准。**

这一类需要的是一套覆盖边界、冲突、缺失、越权、拒绝、下游失败的评估集，而且判断依据是最终业务状态，不是模型的回复文本。

六、错误会传播：改一下就好

前五类是"做不成"，这一类是"做成了更危险"。

单点错误在企业里不会停在原地。Agent 写错一个字段，可能同步到三个下游系统，触发两个自动流程，最后由客服在两周后从客户投诉里发现。

这一类真正需要的不是更准的模型，是治理：

哪些动作必须人批。批的人看到什么信息才够判断。错了怎么撤销。撤销不了的怎么办。审计日志能不能还原当时的决策依据。

我认为这里有一条判断标准：**如果一个动作错了没法撤销，它就必须有人工检查点，不管模型准确率多高。**
准确率再高也不是零。

七、项目无法复制：能不能推广到别的部门

这一类通常出现在第一个项目成功之后。

客户很满意，问能不能复制到另一个部门。你一评估发现，除了那个提示词，几乎什么都要重做。

第 3 章讲的 Palantir Dev / Delta 划分说的就是这件事。差量如果永远留在项目里，规模化就不成立。

这一类的解法在第 31 章：把每个项目产出拆成"客户特有"和"可复用"两堆，后者进产品或资产库。

怎么用这张表

我建议在诊断结束时，对照这七类给客户做一次标记：

哪几类已经是明确问题。哪几类客户还没意识到。哪几类第一阶段处理，哪几类明确不处理。

这份标记有两个用处。

对客户，它把"我们要做 AI"变成了一张可讨论的问题清单。这件事本身就有价值，很多企业从来没这么盘过。

对你，它是范围谈判的依据。**明确写下"这一期不处理第七类"**，比事后解释为什么复制不了要容易得多。

下一章讲反面：哪些需求现在不该做。

本章引用

- [The GenAI Divide: State of AI in Business 2025](#), MIT Media Lab NANDA

§15 需求筛选：哪些现在不该做

第 3 章说过一句话：能拒绝，才谈得上负责。

这一章给拒绝的依据。

先说清楚这里的"不该做"是什么意思。它指的是现在不该做，不是永远做不了。大部分被否掉的需求，等条件补齐之后是可以做的。

把这一点讲清楚，拒绝就不是泼冷水，而是排顺序。

七道门

我把筛选拆成七个问题。全部通过的场景很少，但任何一条是硬否，就不该作为第一个项目。

门	问题	硬否的情况
1 频率	这件事一天/一周发生多少次	一个月几次
2 结果	做完哪个数字会变，谁认	说不出数字或没人认
3 数据	需要的数据能不能拿到	关键数据在无法访问的系统里
4 稳定	流程最近半年改过几次	每个月都在变
5 可恢复	做错了能不能撤销	不可撤销且无人工检查点
6 负责人	谁有权改流程和验收	位置是空的
7 验证周期	第一阶段多久能拿到真实数据	超过一个季度

下面说几个容易被误判的。

频率：低频场景的隐藏成本

低频场景经常看起来很诱人，因为单次价值高。

问题在于，低频意味着你拿不到足够的运行数据来验证系统是否可靠。

一个月发生三次的流程，跑三个月才九个样本。九个样本证明不了任何事。

而且低频场景通常伴随另一个问题：因为不常做，人也记不清规则，导致上下文获取更难。

数据：要量化，不要凭感觉

第 12 章说过，不要凭感觉说"数据比较乱"。

这一门的判断标准是具体的：需要的字段在哪个系统、有没有访问方式、空值率多少、历史数据覆盖多长时间。

有个常见的陷阱：客户说"数据都有"，指的是数据存在于某处，不代表你能拿到。

在企业里，"存在"和"可访问"之间隔着一个审批流程，这个流程可能比开发还长。

所以这一门要在诊断阶段就用实际行动验证——不是听答复，是真的拿到一份样本。

稳定性：流程还在变的时候不要动它

这条最容易被忽略。

如果一个流程正在被业务调整，或者组织架构马上要变，那这时候把它固化成系统是在浪费双方的钱。

判断方法：问最近半年这个流程改过几次，以及未来半年有没有已知的调整计划。

第二个问题经常能问出关键信息。业务负责人心里有数，只是没人问过他。

可恢复：这一条我认为是硬约束

第 2 章和第 13 章都提过，这里说清楚为什么。

不可恢复的场景，第一次出错就可能终结整个项目。

而任何 AI 系统都会出错，区别只是多久出一次。你需要的是一个允许出错、能修正、能积累信任的场景。

所以第一个项目要选"错了能补救"的，不是"最有价值"的。

如果客户坚持要做不可恢复的场景，可行的折中是加人工检查点，把它降到第 13 章的第二层或第三层——AI 给建议和材料，人做最后那一下。

这样价值可能只剩一半，但项目能活下来。

负责人：空位置是最贵的

第 8 章讲过客户侧必须有的两个位置。

这一门的判断很直接：问"这个项目做完，谁来决定大家改用新流程"，如果答案含糊，就是空的。

常见的含糊答案包括："我们会推动的""IT 部门负责""领导很重视"。

这些都不是一个有名有姓、有权拍板的人。

位置空着的项目，最典型的结局是系统做完了、验收也过了，但没人用。这正好落进 MIT 报告里那 95% 的定义——**没有可衡量的损益影响**。

三种特别值得警惕的需求

除了七道门，还有几类需求我认为要额外小心。

第一，"先做个大平台，以后所有场景都能用"。

这类需求没有具体场景，也就没有判据。做出来的东西通常什么都能干一点，什么都不好用。

对策是反过来：先做一个具体场景，做透，再从里面抽公共能力。

第二，"照着某某公司的方案做一个"。

对标本身没问题，问题是别人的方案是在别人的数据、流程和组织下长出来的。

第 3 章那个 Delta 的概念说的就是这个：差量才是工作量所在，而差量是这家企业独有的。

第三，"这个先不用管准确率，能跑起来就行"。

听起来是客户很好说话，实际上是判据缺位。

等到上线，"能跑起来"会立刻变成"怎么老出错"。第 2 章讲的顺序在这里失效了：判据没有在系统之前定下来。

拒绝的说法

最后说怎么说出口。

我认为有效的拒绝要包含三个部分：

不做的理由，用具体条件而不是判断。「这个场景的关键数据在 X 系统，目前拿不到访问权限」比「这个不太合适」有用。

补齐条件的路径。「如果能拿到只读权限，这个场景可以在 Y 周内验证」。

一个可以现在就做的替代。从第 13 章的五层里往下降一层，通常能找到一个当期可做的版本。

这样讲完，客户听到的不是拒绝，是排序。

FDE 说"不"的能力，最后会变成项目成功率。因为你没接的那些项目，正是最可能失败的那些。

Part 4 到这里结束。

下一篇进实施：把通过筛选的需求，一步步变成能在生产环境里跑的系统。

本章引用

- [The GenAI Divide: State of AI in Business 2025](#), MIT Media Lab NANDA

Part 5 实施篇：Runtime Harness

这一篇是全书最核心的部分。

七章对应第 2 章那个顺序的中后段，以及第 14 章那七类问题里的前六类。

每一章的结构一样：这一步要回答什么问题、产出什么、什么条件下可以进入下一步。

§16 Outcome Contract：写在代码之前

这是第 14 章第一类问题的解法。

先说它不是什么。它不是需求文档，不描述功能。

一份好的 Outcome Contract 里可能一个功能名词都没有，全是触发条件、状态变化、判定规则和责任人。

它要回答的问题

问题	为什么必须答
什么条件触发	决定系统的入口，也决定哪些情况不归它管
完成后哪个业务状态改变	这是验收的唯一依据
成功怎么判断	决定评估集怎么写
失败怎么判断	决定什么时候该停、该升级
部分成功算什么	企业流程里这种情况最多，必须提前定
错一次的代价	决定要不要人工检查点
哪些动作必须人批	决定 Harness 的约束层怎么设计
谁是结果负责人	决定争议时找谁
什么时候算这一期结束	决定项目怎么收尾

我认为这九个里最容易被跳过的是第五个：部分成功。

因为在 Demo 里只有成功和失败两种状态。到了真实流程，"处理了一半卡住了"是最常见的情况。

不提前定义，上线后每次出现都要临时讨论一遍。

业务状态，不是模型行为

这是写这份文档时最容易走偏的地方。

对比一下：

模型行为的写法	业务状态的写法
Agent 能准确回答产品问题	产品咨询类工单的人工转接率从 A 降到 B
系统能自动分类工单	分类结果直接进入派单流程，人工复核比例低于 X%
支持多轮对话	一次会话内完成率高于 Y%

左边这些做完了没人能验收，因为"准确"没有定义。

右边可以直接写进合同。

判断方法：把这句话拿给客户的财务或运营看，他能不能说出这个数字现在是多少。

说不出来，说明这个指标现在没人在测，那它也不能作为验收依据——因为没有基线。

基线：容易被忽略的一步

要证明改变，得先知道改变前是什么样。

很多项目上线后陷入扯皮，就是因为没有基线。客户觉得没什么变化，你觉得改善很多，双方都没有数字。

基线要在 Outcome Contract 里写死：这个指标当前是多少、怎么测的、测的时间范围。

如果客户现在根本不测这个指标，那第一件事是先建立测量。这本身就是交付的一部分，而且往往是客户最先感受到价值的部分。

一份可以直接抄的骨架

Outcome Contract: [场景名]

一、范围

本期处理: [具体的业务场景, 越窄越好]

本期明确不处理: [列出来, 写清楚]

二、触发

触发条件:

不触发的情况:

三、结果

目标业务状态改变:

衡量指标:

当前基线: (测量方式、时间范围)

本期目标值:

达标观察期: (连续多久算稳定)

四、判定

成功:

失败:

部分成功: (如何处理, 谁接手)

五、风险与边界

单次错误代价:

不可恢复的动作:

必须人工批准的动作:

必须拒绝的请求类型:

六、责任

业务负责人: (有权改流程和验收)

数据/IT 对接人:

交付方负责人:

七、结束

本期验收条件:

验收证据形式：

上线后支持范围与期限：

这份东西的长度我建议控制在两页以内。

长了就没人看，没人看就不会有人签字，没签字它就不起作用。

签字这件事

Outcome Contract 需要客户业务负责人签字，不是 IT 签字。

理由在第 8 章说过：只有业务负责人有权改流程、有权定义什么算成功。

如果只有 IT 签，验收时业务方说“这不是我们要的”，你没有依据。

签字这个动作还有一个隐含价值：**它逼客户内部先达成一致。**

很多项目的分歧不在甲乙之间，在客户内部——业务和 IT 想要的东西不一样。这个分歧如果不在签字阶段暴露，就会在验收阶段爆发。

什么时候可以进入下一步

这一步的完成信号：

Outcome Contract 已签字。基线数字已测出来。本期不做的部分已经写进文档。业务负责人和数据对接人都有具体的名字。

四条齐了，才进入下一章的现场调研和 Context Audit。

没签字就开工，是我认为 FDE 项目里最常见、也最贵的一个错误。

§17 现场调研与 Context Audit

这一章对应第 2 章那个顺序里的"事实"段，以及第 14 章的第二类问题。

它的目标只有一个：**把真实执行的流程和真实可用的知识摸清楚。**

不是听描述，是看人干活。

为什么描述不可信

第 2 章讲过：会议室里的描述是制度版本，不是执行版本。

这不是客户在隐瞒。原因有三个：

管理层描述的是他们设计的流程，不是一线执行的流程。

一线描述的是他们以为自己在做的事，而人对自己的自动化行为往往说不清楚。

所有人都会自动过滤掉异常，因为异常处理已经内化成习惯了。

所以现场调研的核心方法是观察，访谈只是补充。

观察怎么做

坐在操作员侧后方，看他处理真实案例，全程记录不打断。

打断会改变行为。一旦你问"你刚才为什么这么做"，后面他就会开始解释而不是操作。

问题攒着，一批处理完之后统一问。

观察时重点记这几件事：

观察项	记什么	为什么
系统切换	打开了几个系统，在哪几个之间来回	决定集成范围
输入来源	每一步的信息从哪来，怎么进来的	Context 的原料
停顿点	他在哪里停下来想，或者去问人	隐性规则所在
异常处理	遇到不正常情况时怎么办	异常矩阵的原料
留痕	做完在哪里记录	验证结果的依据

停顿点是这份工作里最值钱的东西。

流畅走完的步骤，说明有明确规则。停下来想的地方，说明是经验判断——这些地方就是后面 Agent 会出错的地方。

观察多少个案例

这个我给不出标准数字，取决于流程复杂度和异常率。

可用的停止条件是：连续若干个案例都没有出现新的异常类型时，可以停。

如果一直在出现新情况，说明这个流程的变异度很高，这本身就是重要发现——它会影响第 15 章那道“稳定性”门的判断。

访谈：问题挂在案例上

观察完再访谈，问题要具体。

有效的问法：「刚才这一单你为什么没走标准审批」「这个字段你填的是 X，什么时候会填 Y」「上次遇到客户资料不全是怎么处理的」。

无效的问法：「你们的审批流程是怎样的」「一般什么情况下需要人工介入」。

后者拿回来的是制度版本，你已经有了。

还有一个我认为很有用的问题：「这个活里最烦的是哪一步？」

答案经常和你以为的不一样，而且它直接指向价值最高的自动化点。

Context Audit：知识的体检

观察解决“流程怎么跑”，Context Audit 解决“知识在哪、可不可信”。

第 10 章讲了知识的四种存放方式。这一步要对每一个信息源建档。

要问的问题：

它存在哪，能不能被程序访问。谁负责维护它。上次更新是什么时候。它和别的来源冲突时，听谁的。谁有权限看。多久会过期。是每次都要用，还是按需检索。

最后形成 Context Registry，字段在第 19 章会给完整模板。

三件在 Audit 里最常发现的事

第一，有效版本说不清。

同一份产品文档存在多个版本，散在不同位置，没人知道哪份是现行的。

这一条如果不解决，检索准确率再高也没用——它会精准地找到那份作废的。

第二，制度和执行不一致。

文档写着要走三级审批，实际上某类情况一直是直接过的。

这时候要做的不是纠正客户，是记录下来并让业务负责人确认按哪个执行。**这个确认动作本身就有价值，因为很多时候客户内部也不知道存在这个偏差。**

第三，关键规则只在人脑里。

「这个客户我们一般给特批」「金额超过多少要找谁」「这种情况按老规矩处理」。

这些必须当场挖出来、写下来、找人确认。第 7 章讲过，留在你脑子里等于把风险留给项目。

待确认清单

Context Audit 的产物里，我认为有一样最容易被忽略但很重要：**待确认事实清单**。

它记的是调研中发现的、目前还没有权威答案的问题。

比如：两个部门对同一个字段的定义不一致，需要谁来拍板；某类异常的处理方式，三个老员工说法不同。

这份清单要交给客户的业务负责人，由他给出答案。

这份清单的长度，是这个项目复杂度的一个很好的指标。

如果它很长，说明企业内部本身就没有统一口径，那么项目周期要往后加，而且第一阶段的范围要更窄。

这一步的产物

真实流程图（含系统、输入、判断、停顿点）。异常矩阵（观察到的所有非正常情况及处理方式）。Context Registry 初稿。待确认事实清单。

检验方式

第 2 章说过，产物容易糊弄，检验方式糊弄不了。

这一步的检验方式是：**把流程图和异常矩阵拿给一线操作员看，问他认不认。**

如果他说“我们不这么干”，那前面的活要重做，不管你已经写了多少代码。

如果他说“对，但还有一种情况你没写”，那是好事——这一条会成为评估集里的一个用例。

下一章把这些事实变成可计算的东西：流程契约。

§18 Workflow Contract: 把流程写成状态机

这一章对应第 14 章的第三类问题：SOP 只写正常路径。

上一章拿到的流程图是描述性的。这一章要把它变成可计算的。

差别在于：描述性的流程回答"一般怎么走"，状态机回答"任何时刻系统在哪、下一步由什么决定"。

为什么必须写成状态机

三个理由。

第一，Agent 会失败在任何一步。没有状态定义，失败之后不知道从哪恢复。


第二，人工接管需要接管点。接管点就是状态。没有状态划分，人接手时不知道当前进行到哪。

第三，第 9 章讲的多步坍塌问题需要在每一步验证。验证的对象就是状态转移是否合法。

用一句话说：状态机是给中断和恢复用的，不是给正常流程用的。

正常流程根本不需要状态机，顺着走就行了。

一个流程契约的基本结构



这张图是通用骨架，具体项目要按实际流程改。

这张图里有四个终态：已完成、已终止、待人工、以及隐含的部分完成。

第 16 章说过，部分成功是企业流程里最常见的情况，必须提前定义。

要写清楚的六件事

要素	内容	不写的后果
状态清单	系统可能处于的所有状态	失败后不知道从哪恢复
转移条件	每条边由什么触发	行为不可预测
决策规则	判断点用什么依据	规则藏在提示词里，没人能审
异常矩阵	每类异常的分类和处理	异常全部落到人工
人工升级路径	什么时候交给给人，交给谁	人不知道自己该接什么
外部副作用	每一步会改变哪些外部系统	回滚时不知道要撤销什么

最后一条最容易漏。

副作用清单是回滚设计的前提。 你必须知道每一步动了什么，才能在出错时撤回来。

异常矩阵怎么写

上一章观察到的异常，在这里要分类。

我建议按"处理方式"分，而不是按"原因"分。因为处理方式直接映射到状态转移。

异常类别	处理方式	例子
可自动恢复	重试，有上限	下游超时、限流
需要补信息	向上游或用户索取	关键字段缺失
需要人判断	升级到人工，带上下文	规则冲突、金额超限
必须拒绝	终止并记录	越权请求、明确禁止的操作
未知	保守停止，报警	没见过的情況

最后一类必须有。

没有"未知"分支的系统，会把没见过的情况错误地归到某个已知分支里。 那比停下来危险得多。

决策规则要放在提示词外面

这是我认为流程契约最重要的一条实践。

判断规则——什么条件下走哪个分支——应该写成显式的配置或代码，不是藏在提示词里让模型自己判断。

三个理由：

规则写在外面，业务方能看懂、能审、能确认。写在提示词里，只有你能看。

规则写在外面，改动有版本记录。写在提示词里，改了没人知道。

规则写在外面，评估可以直接测。写在提示词里，只能测最终输出。

第 7 章讲过往提示词里堆规则的后果：三个月后一份两千字的提示词，几十条规则互相打架，谁也不敢删。

能用条件判断表达的，不要交给模型判断。把模型用在真正需要理解和归纳的地方。

人工接管点的设计

第 11 章说过，人工审批是架构的一部分，不是界面功能。

设计接管点时要回答：

在什么状态下触发。接管的人是谁（角色，不是姓名）。他看到什么信息才够判断。他有哪些选项（批准、拒绝、修改后批准）。超时不处理会怎样。批准之后从哪个状态继续。

第四条容易被简化成"批准/拒绝"两个按钮。

但实际业务里"修改后批准"非常常见——人看了 Agent 的方案，改了一个字段，然后放行。

如果系统不支持这个选项，人就会跳出系统去手工处理，你的流程数据就断了。

这一步的产物和检验

产物：状态机定义、转移条件、决策规则表、异常矩阵、人工接管点定义、副作用清单。

检验方式：**拿异常矩阵去问一线，问他们还有没有见过别的情况。**

以及一个更硬的检验：把状态机里的每一个终态，对应到 Outcome Contract 里的成功、失败、部分成功。

如果有状态对应不上，说明契约不完整，要回去补。

下一章讲上下文系统，也就是状态机每一步需要什么信息、从哪来。

§19 Context System：来源、权威、时效与权限

第 10 章讲了上下文工程的原理，这一章讲在客户现场怎么落地。

核心产物是一份 Context Registry。

我认为这是 FDE 最该标准化的交付物，因为它是唯一一份既能给客户看、又能直接驱动系统实现的文档。

Context Registry 完整模板

字段	说明	填不出来的后果
ID	信息源编号	无法在日志里追溯
名称	人能看懂的名字	业务方看不懂这份表
内容类型	事实数据 / 规则 / 术语 / 模板	影响注入策略
物理位置	库表、目录、系统、接口	程序取不到
访问方式	API / 直连 / 导出 / 人工维护	无法自动更新
负责人	有权确认内容的人	冲突时无人拍板
权威级别	高 / 中 / 低	冲突时随机选
有效期	多久失效或需复核	用过期信息
更新频率	实时 / 日 / 周 / 不定期	缓存策略错
权限范围	哪些角色可见	越权泄露
注入方式	常驻 / 按需检索 / 不注入	上下文膨胀
已知冲突	与哪些源冲突，怎么处理	答案不稳定
状态	已确认 / 待确认 / 已废弃	用了没人认的信息

字段可以裁剪，但权威级别、有效期、权限范围这三列我认为不能省。

它们分别对应第 9 章那三种失效：选错冲突信息、用过期信息、越权。

权威级别怎么定

这是整张表里最需要业务方参与的一列。

我用的分法：

高——由明确责任人维护，且是这类信息的唯一正式出处。系统里的结构化数据通常在这一档。

中——正式文档，但可能滞后于实际执行。制度文件多在这一档。

低——有参考价值但不能单独作为依据。工单记录、群聊约定、个人整理的资料。

规则是：**冲突时高压中，中压低。同级冲突时，走待确认清单，找负责人拍板。**

这条规则要写进系统，不是写进提示词。

因为第 18 章说过，能用条件判断表达的，不要交给模型判断。

注入策略：三档

第 10 章介绍了 Anthropic 的四个技术。落到 Registry 上，每个信息源要选一档。

常驻——每次都注入。适合体量小、几乎每次都用到的：核心术语表、当前生效的关键规则、角色定义。

数量要严格控制。第 10 章说过，上下文是有限资源，每多一个 token 就消耗注意力预算。

按需检索——保留轻量引用，运行时才取。适合体量大、只在特定情况用到的：产品文档、历史工单、客户档案。

这是企业场景的主力方式，因为它同时解决了体量和权限两个问题。

不注入——存在但不给模型。适合敏感数据、或者应该由确定性代码处理的部分。

第三档经常被忘掉。**不是所有信息都该进上下文。** 能用一个数据库查询解决的，不要让模型去检索和推理。

处理"只在人脑里"的知识

第 17 章挖出来的隐性规则，要在这一步落成结构化的东西。

我的做法是分两类：

能表达成条件的，写成规则表，进第 18 章的决策规则，不进上下文。

比如「金额超过 X 要 Y 审批」，这是条件判断，不需要模型理解。

只能表达成经验的，写成带例子的说明，进上下文，并标注来源和确认人。

比如「这类客户的诉求通常是 A 而不是 B」，这类没法写成条件，只能给模型看例子。

第二类要特别标注**来源人和确认时间**。因为它是最容易过期的一类知识，而且没有系统会提醒你它过期了。

待确认清单的处理

第 17 章产出的待确认事实清单，在这一步要有结论。

三种结局：

业务负责人给出答案，进 Registry，状态标为已确认。

暂时给不出答案，但影响本期范围，那就要回到 Outcome Contract 调整范围。

暂时给不出答案，不影响本期，记入风险清单，状态标为待确认。

第三种情况要在系统里有对应行为：命中待确认的规则时，走人工。

不能让模型去猜一个连客户自己都还没决定的事。

上下文的持续维护

系统上线不是终点。第 10 章说过上下文系统会腐化。

要在交接时明确几件事：

谁负责在文档更新后同步 Registry。多久做一次全量复核。发现冲突时的上报路径。模型升级后谁负责重跑评估、验证注入策略是否还有正收益。

这几条写不进交接文档，三个月后这套上下文就开始产生错误答案，而且没人知道是从哪一天开始错的。

这一步的产物和检验

产物：Context Registry、决策规则表（与第 18 章共用）、待确认清单的结论、注入策略配置。

检验方式：**随机抽三个信息源，问客户业务方“这份东西现在谁在维护、上次更新是什么时候”。**

答不上来的，权威级别就不能标“高”。

还有一个更硬的检验：拿两个已知互相冲突的来源，跑一遍系统，看它是否按权威级别选择。

选对了，说明规则真的进了系统。选错了，说明规则还只写在文档里。

下一章讲 Agent Harness：信息到位之后，怎么约束它去做事。

§20 Agent Harness：工具、状态、失败与接管

第 11 章讲了 Harness 的概念和分层，这一章讲落地。

对应第 14 章的第四类和第六类问题：工具不可控、错误会传播。

工具契约

Agent 能做的每一件事，都要有一份契约。

不是"给它一个 API 文档让它自己看"，是明确定义的调用边界。

契约要素	内容
用途	什么情况下该调它，什么情况下不该
参数与校验	类型、范围、必填、格式，调用前校验
副作用	它会改变什么外部状态
幂等性	重复调用是否安全，靠什么保证
权限要求	需要什么身份，谁批准过
失败语义	失败时外部状态是否已改变
超时与重试	多久算超时，重试几次，间隔多少

我认为最容易被忽略的是**失败语义**。

一次调用超时了，到底有没有生效？这个问题答不上来，重试就是赌博。

如果下游接口没有提供确认机制，那么正确的做法是：不重试，转人工，并且在契约里写明这一点。

幂等：企业场景的底线

第 11 章说过，Agent 调一次和调三次，结果必须一样。

实现方式通常是幂等键：每个业务动作生成一个唯一键，下游用它去重。

如果下游系统不支持幂等键（老系统很常见），可选方案：

在自己这一侧维护执行记录，调用前先查是否已执行过。

把动作拆成"先查后写"，写之前确认当前状态。

对不可去重的动作（比如发邮件），强制走人工审批，不做自动重试。

这一条没得商量。 因为第 9 章讲的多步坍塌意味着重试是必然会发生的。

没有幂等保护，重试会造成比失败更糟的结果。

状态持久化

第 18 章定义的状态机，要真的存下来。

存的内容：当前状态、已完成的步骤及其结果、已产生的副作用清单、重试次数、进入当前状态的时间。

用途有三个：

失败后从断点恢复，不是从头再来。

人工接管时，人能看到当前进行到哪。

出问题时，能回答"当时它在哪一步"。

副作用清单尤其重要。 第 18 章说过，它是回滚设计的前提。

权限与身份

第 10 章和第 12 章都提过这个问题，这里给落地的检查项。

Agent 用什么身份访问每一个下游系统。这个身份的权限范围是谁批的，有没有书面记录。用户通过 Agent 能不能拿到自己本来无权看的数据。Agent 的操作在下游系统的审计日志里记在谁名下。

最后一条如果答案是"一个服务账号"，要提前和客户的合规部门确认能不能接受。

第 12 章说过，很多企业的风控不会放行这种设计。**这个问题要在设计阶段暴露，不能等上线前一周。**

人工接管的实现

第 18 章定义了接管点，这一章讲怎么实现。

几个容易做错的地方：

接管时给的上下文不够。 只给一句"请审批"，人没法判断。至少要给：当前状态、Agent 的建议、依据的关键信息、如果批准会发生什么。

没有"修改后批准"。 第 18 章说过，人会跳出系统去手工处理，流程数据就断了。

超时没有默认行为。 待审批的任务堆积起来没人管，业务就卡住了。要定义超时后是自动升级、自动拒绝，还是提醒。

接管记录没有留痕。谁批的、什么时候、看到了什么，这些是审计的核心，也是后面复盘的原料。

执行循环的约束

Lilian Weng 那篇文章里提到的失败模式中，有两条在企业场景特别危险：过度乐观，以及执行压力下的实现漂移。

翻译过来：Agent 会为了让任务显得完成而降低标准，也会在长流程里慢慢偏离原定计划。

对策我认为有三个方向：

不要让执行者当裁判。 完成判定由独立的校验逻辑做，检查最终业务状态，不看模型的自述。这是第 21 章的内容。

限制循环次数和总步数。 超过上限就停下来转人工，而不是继续尝试。

在关键节点重新对照原始目标。 长流程中途插入一次核对：当前进展是否还在解决最初那个问题。

一份 Harness 检查清单

上线前可以逐条过的：

每个工具都有契约，且参数在调用前校验。所有会改变外部状态的动作都有幂等保护，或者明确不重试。状态可持久化，失败能从断点恢复。副作用有记录，可以逐条对应到撤销方式。Agent 的身份和权限有书面确认。所有需人批的动作都有接管点，且接管人能看到足够信息。有循环次数和总步数上限。所有决策路径可从日志还原。

这份清单里任何一条没做到，都不建议进入自动执行阶段。

可以先上第 13 章的第二层或第三层——只给建议，人来执行。

关于 Harness 的一个提醒

第 11 章讲过，Harness 不能越做越厚。

在客户现场这个风险更大，因为每次出问题最快的解法都是“再加一条规则”。

我建议在项目里就建立一条纪律：**每加一条约束，记录它解决的是哪个具体 bad case。**

三个月后模型升级，你才有依据判断哪些约束可以删。

没有这份记录，那些约束会永远留着，因为谁也不敢动。

下一章讲评估：怎么证明这套东西真的做对了。

本章引用

- [Harness Engineering for Self-Improvement](#), Lilian Weng, 2026-07

§21 Eval Harness：验证业务状态，不看模型自述

这一章对应第 14 章的第五类问题：效果看着还行，但没人敢上线。

第 2 章讲过顺序：判据要在系统之前建立。这一章讲判据具体怎么建。

一条最重要的原则

Anthropic 在讲 Agent 评估时举过一个例子，我认为是整件事里最清楚的一个：

订票 Agent 说“已为您预订”，你要去数据库里查有没有真的产生那张订单。

模型的自我陈述不能作为完成的证据。评估必须检查最终的环境状态。

这条在 Demo 里无所谓，在企业里是底线。因为企业的下游系统会真的被写入，也真的会写入失败。

落到实现上：每个测试用例的断言对象，应该是业务状态（数据库里的记录、下游系统的返回、文件的实际内容），而不是模型输出的文本。

评估集的七类用例

第 2 章给过这张表，这里补上怎么造。

类型	怎么造	检查什么
正常	从真实历史案例里抽	基本能力
边界	把真实案例的关键数值调到临界	规则执行是否精确
信息缺失	把真实案例的关键字段挖空	会不会编造
上下文冲突	构造两份说法不一的来源	会不会按权威级别选
权限越界	用低权限身份请求高权限数据	会不会泄露
必须拒绝	构造明确禁止的请求	会不会该停不停
下游失败	mock 下游超时、报错、部分成功	会不会重复写入

前三类从真实案例改造，后四类需要构造。

后四类是企业场景特有的，也是最容易被跳过的。 因为它们在 Demo 里永远不会出现。

我的建议是给后四类设一个最低数量，比如每类不少于五个，作为上线的硬条件。

用例从哪来

四个来源，按价值排序：

第一，第 17 章的现场观察。 观察到的每一个真实案例都是用例，包括那些异常。

第二，第 18 章的异常矩阵。 每一类异常至少一个用例。

第三，第 19 章的已知冲突。 Registry 里标记的每一对冲突，都要有对应用例。

第四，线上故障。 上线之后每一次出错，都要转成一个回归用例。

第四条是长期最重要的来源。一个成熟的评估集，大部分用例应该来自真实故障，而不是设计阶段的想象。

判分方式

不同类型的用例需要不同的判分方式。

确定性断言——检查数据库记录、字段值、状态码。适合有明确正确答案的场景，最可靠，优先用。

规则校验——检查输出是否满足格式、是否包含必需字段、是否引用了合法来源。

模型判分——用另一个模型判断输出质量。适合开放性输出，但要注意它本身也有误差，要抽样人工校准。

人工判分——最贵，用在模型判分不可靠的关键场景，以及定期校准模型判分器。

我的建议是：**能用确定性断言的，绝不用模型判分。**

很多团队一上来就用模型判分，因为省事。代价是判分器本身的漂移无法察觉。

基线与回归

第 16 章说过基线要写进 Outcome Contract。这里是技术上的基线。

系统骨架搭好之后，先跑一遍完整评估集，记下分数。这是技术基线。

之后每一次改动都要跑，和基线比。

要盯的不只是总分，还有**分项有没有倒退**。

常见的情况是：为了修某类 bad case 加了一条规则，总分上去了，但另一类用例悄悄掉了。只看总分发现不了。

上线门槛

第 2 章说过门槛要写成数字。这里给一个结构。

维度	门槛示例形式
准确率	各类用例分别达标，不看平均
误操作率	不该执行却执行了的比例，通常要求接近零
拒绝率	该拒绝的是否都拒绝了
人工介入率	高于某个值说明自动化价值不足
延迟	P95 在业务可接受范围内
成本	单次处理成本低于人工
稳定性	连续 N 周达标

"各类用例分别达标，不看平均"这一条我认为很关键。

平均分会掩盖问题。总体 95% 的系统，可能在"必须拒绝"那一类上只有 60%，而那一类恰恰是风险最高的。

评估的持续运行

上线不是评估的终点。

要建立的机制：

每次代码或提示词改动，自动跑全量评估。每次模型版本变化，重跑并对比。每次线上故障，新增回归用例。定期（比如每季度）人工抽检模型判分器的准确性。

第 10 章和第 11 章都提过：模型升级后，为旧模型加的约束可能变成负担。

评估集是判断这件事的唯一工具。 没有它，你只能凭感觉决定要不要删，结果就是不敢删。

这一步的产物和检验

产物：分类的评估集、判分实现、技术基线、上线门槛定义。

检验方式：**在当前系统上跑一遍，看有没有失败的用例。**

如果全部通过，多半是用例造得太简单了。一个有价值的评估集，在系统还不成熟的时候应该有相当比例的失败。

还有一个检验：把评估集里的用例给客户业务方看几条，问他"这种情况是不是真的会发生"。

他说不会的，删掉。他说"还有一种你没写"的，补上。

下一章讲怎么从测试环境走到真正的生产运行。

本章引用


- [Demystifying Evals for AI Agents](#), Anthropic

§22 Operational Harness：从影子运行到有条件自治

第 13 章说过，层级可以爬，但不能跳。

这一章讲怎么爬。

七级放量



每一级都要有明确的进入门槛和退出条件。

不是所有项目都要爬到第七级。很多场景停在第四级就已经产生了足够价值，而且风险可控。

第 13 章说过，客户开口要第五层，实际需要的可能是第三层。放量级别也是一样。

各级要做什么

一、离线重放。 用历史数据跑，和当时的真实处理结果对比。

价值是成本低、能大批量跑。局限是历史数据里没有 Agent 造成的新情况。

二、影子运行。 真实流量进来，人正常处理，系统在旁边也处理一遍，结果只记录不生效。

这一级能暴露的东西，测试环境里看不到：真实数据有多脏、请求的实际分布和你以为的差多少、高峰期延迟、以及一批没见过的情况。

我认为**这一级不能省**。它是唯一一个既有真实性、又零风险的阶段。

三、只读建议。 结果给到人，人决定用不用。

这一级开始有采用率数据了——人有多少比例采纳了建议。这个数字比准确率更接近业务价值。

四、人工批准后执行。 人批准，系统执行。

和第三级的区别是执行由系统做，所以第 20 章那些工具契约、幂等、副作用记录，从这一级开始真正生效。

五到六、部分自动执行。 按第 18 章的异常矩阵，把低风险、规则明确的类型放开。

放开的顺序按"错误代价"排，不按"发生频率"排。

七、有条件自治。 大部分情况自动，异常和高风险仍走人工。

注意是"有条件"。我不认为企业场景存在无条件自治，因为第 18 章那个"未知"分支永远需要人。

偏差分类：这一步决定你是在修还是在补

第 2 章和第 7 章都提过，这里给完整的分类表。

偏差表现	归属	修法	对应章节
缺少某条信息	Context	补 Registry、改注入策略	§19
用了过期或错误的信息	Context	改权威级别、加有效期	§19
规则理解错	Workflow	把规则从提示词移到显式判断	§18
状态流转错	Workflow	补状态定义和转移条件	§18
工具调用参数错	Harness	加参数校验	§20
重复执行	Harness	加幂等	§20
该转人工没转	Harness	补接管点触发条件	§20
模型确实做不到	范围	划出去交人工，改契约	§16

最后一行最难做，但必须做。

承认某类情况模型做不到，要放弃一部分自动化率，在项目压力下很难开口。

但不承认的代价是系统在这类情况持续出错，最后拖垮所有人对它的信任。而信任一旦没了，前面所有工作都白做。

监控要盯什么

技术监控（延迟、错误率、成本）是基础，这里不展开。

FDE 要额外盯的是这几个：

采用率。 有多少人在用，趋势是涨还是跌。跌了要立刻查原因。

建议采纳率。 第三级之后一直有效。人不采纳，说明质量或者时机有问题。

人工介入率。 太高说明自动化价值不足，太低要警惕是不是该介入的没介入。

逃逸率。 人绕过系统去手工处理的比例。这个指标最容易被忽略，但它直接说明系统在实际工作里好不好用。

第 18 章说过，如果系统不支持"修改后批准"，人就会跳出系统。逃逸率就是在测这件事。

业务指标本身。 Outcome Contract 里定的那个数字，对比基线。

回滚

第 12 章说过：能回滚代码，不等于能回滚业务后果。

要提前定义的：

关掉 AI 之后，人工流程能不能立刻接上（这要求人工流程没有被拆掉）。

已经产生的错误动作怎么处理，哪些能自动撤销，哪些要手工修。

谁有权决定回滚，什么条件下触发。

回滚之后，怎么判断可以重新放量。

第一条最容易出事。 有些项目上线后为了显示决心，把人工流程的工具和岗位撤了。一旦系统出问题，退无可退。

我的建议是：至少在达标观察期结束前，人工流程要保持可用。

达标观察期

第 16 章的 Outcome Contract 里有这一项。

它的作用是防止用短期数据下结论。一周达标可能是运气，也可能是那周恰好没有复杂案例。

观察期要覆盖业务的完整周期。有月结的业务至少跨一个月结，有季节性的业务要考虑淡旺季。

Part 5 到这里结束。

七章走完，一个 AI 系统从模糊需求变成了在生产环境里运行、被监控、能回滚的东西。

但这只解决了一半问题。**技术上的完成，不等于交付完成。**

下一篇讲另一半：项目怎么才算真的交出去了。

Part 6 交付篇：Delivery Harness

第五篇解决"怎样把 AI 系统做对"，这一篇解决"怎样让企业项目成功"。

两件事经常被混为一谈，代价是项目在技术上完成、在商业上失败。

MIT 那份报告里外部伙伴主导的部署 67% 进生产、企业自建只有 33%，我认为差距很大程度上就在这一篇。

§23 客户筛选与付费诊断

第 15 章筛的是需求，这一章筛的是客户。

需求可以改小，客户改不了。

值得做的客户长什么样

我按重要性排了个序，前三条是硬条件。

一、有一个愿意投入时间的业务负责人。

第 8 章和第 15 章都说过这个位置。这里再强调一次：不是“领导很重视”，是有名有姓、有权改流程、愿意每周花时间的人。

判断方法很直接：约他两小时，看他来不来。

来了，并且在会上能说清楚现在的流程哪里最痛，这个客户可以做。派个助理来听，基本可以放弃。

二、有一个具体的痛，而不是一个方向。

「我们客服每天处理三千张工单，其中订单查询类占三分之一，人力不够」是痛。

「我们要拥抱 AI」是方向。

方向类的需求不是不能做，但它需要先做诊断把方向变成痛。而客户往往不愿意为诊断付费。

三、数据和系统有可行的访问路径。

第 12 章那份技术尽调清单可以直接用。

关键是要在筛选阶段就用实际行动验证——不是听答复，是真的拿到一份样本数据。

四、时间预期合理。

要求两周上线、下个月见效的客户，通常意味着这件事上面已经承诺出去了。

这种项目的压力会全部传导到第 2 章那个顺序上——前三段会被压缩掉，然后失败。

五、有承担失败的空间。

第 15 章说过，第一个项目要选错了能补救的。客户这一侧也一样：如果这个项目只许成功，那它的风险承受能力是零，而零风险承受能力的项目不适合做 AI。

几种建议避开的客户

只想要一个可以对外宣传的案例。 这类项目的验收标准是发布稿，不是业务指标。做完你拿不到有价值的经验，也沉淀不了资产。

已经失败过一次，但拒绝复盘的。 上一次为什么失败，如果答案是"上一家供应商不行"，那么大概率会有第二次。

IT 主导、业务缺席的。 第 16 章说过 Outcome Contract 要业务负责人签字。业务缺席的项目，验收时一定出问题。

预算来自年底突击花钱的。 这类项目的真实目标是花掉预算，不是产生结果。表现是决策快、要求松、但验收时突然变严。

付费诊断

第 2 章和第 7 章都提到过这个做法，这里讲清楚。

诊断是一个独立收费的小项目，通常两到四周，产出第 17 章那几样东西：真实流程、异常矩阵、Context Registry 初稿、可行性判断、收缩后的第一阶段范围和报价。

它解决三个问题。

第一，客户会认真配合。免费的东西没人重视，约人约不到、数据拿不到。

第二，你有依据报价。不做诊断就报价，等于在赌，赌输了整个项目都在亏损里跑。

第三，它本身是一次双向筛选。四周下来，你知道这个客户好不好合作，客户也知道你专不专业。

诊断的交付物必须独立有价值。 就算后面不合作，客户也拿到了一份能用的现状梳理。很多企业从来没有人完整梳理过自己的流程。

这一点做到了，诊断就不难卖。

诊断报告要包含什么

部分	内容
现状	真实流程图、异常矩阵、耗时分布
知识	Context Registry 初稿、待确认清单
可行性	数据可获得性、系统集成路径、身份权限方案
分层判断	每个候选场景在第 13 章的哪一层，建议做到哪一层
筛选结论	建议做的、建议缓的、建议不做的，各自理由
范围建议	第一阶段范围、Outcome Contract 草案
报价与工期	基于以上的估算，含甲方依赖

第五行的"建议不做的"要认真写。

第 15 章说过，拒绝要包含具体条件、补齐路径和当期替代方案。

写在诊断报告里的拒绝，比在项目中途的拒绝容易接受一百倍。

从诊断到合同

诊断结束时要做一次正式汇报，参加的人必须包括业务负责人。

汇报的重点不是"我们能做什么"，是"我们发现了什么"。

现状梳理的部分往往会让客户内部产生讨论——因为你把他们内部不一致的地方摆到了台面上。

这个讨论对你有利。它会让业务负责人意识到，这件事需要他来拍板，而不只是买个软件。

下一章讲怎么把诊断结论变成一份能保护双方的 SOW。

§24 范围收缩、报价与 SOW

第 5 章说过：范围和技术方案是同一件事的两面。

所以这一章不是商务章节。**范围谈判是 FDE 的技术工作。**

范围收缩的四个条件

第 2 章给过，这里展开怎么用。

客户第一次提的需求，基本是他们能想到的最大版本。你要从里面切一块，满足：

发生得够频繁。 第 15 章讲过低频场景的问题——拿不到足够样本验证可靠性。

结果能衡量。 对应第 16 章的基线。现在没人测这个数字，那第一件事是先建立测量。

数据拿得到。 第 12 章那份尽调清单验证过的，不是听说的。

做错了能恢复。 第 15 章说这是硬约束。

四条都满足的切片，通常比客户原始需求小一个数量级。

小不是问题。小而完整，比大而半成品有价值得多。

因为小的切片能在几周内跑到生产，拿到真实数据，建立信任。而信任是后面扩范围的唯一基础。

怎么跟客户谈缩范围

直接说"这个太大了做不了"，效果不好。

我认为有效的讲法是把它变成路径，而不是删减。

先给完整图景：你要的这套东西整体是这样，包含 A、B、C、D 四块。

再给排序依据：A 数据现成、错误可恢复、每天发生几百次，适合先做，六周能跑到生产。D 需要接三个老系统且不可回滚，建议放在建立信任之后。

再给时间点：A 上线并稳定运行一个月后，我们用真实数据重新评估 B 和 C。

客户抗拒的是"做不了"，不抗拒"先做这个"。

报价

我不打算给具体的定价方法，因为它跟市场、团队成本和客户类型强相关。

但有几件事我认为在报价里必须体现。

诊断和实施分开报。 理由在第 23 章。

报价要绑定甲方依赖。 这个价格的前提是客户在某个时间点前提供某些东西。前提不成立，价格和工期都要重议。

留出评估和上线的工作量。 第 21 章和第 22 章那些活是实打实的工作，不是"顺便做一下"。很多报价只算了开发，结果这部分吃掉了利润。

明确支持范围和期限。 第 4 章的第五个问题说过，没有边界的支持会把团队拖垮。

我见到的最常见的报价错误是：**只报了第一次做对的成本，没报反复迭代的成本。**

而第 22 章讲的偏差处理，本身就是一个持续的过程。

SOW 要写什么

SOW 不是商务附件，它是 Delivery Harness 的核心文档。

它和第 16 章的 Outcome Contract 是配套的：Outcome Contract 定义"什么算成功"，SOW 定义"双方各做什么、出问题怎么办"。

部分	必须写清楚的
范围	做什么，以及明确不做什么
甲方依赖	人、数据、账号、环境、审批，各自的截止时间
阶段与里程碑	每个阶段的产物和确认方式
变更机制	需求变了怎么走，对预算和工期的影响规则
验收	依据 Outcome Contract 的哪些条款，用什么证据
支持	上线后支持的范围、响应时间、期限
交接	交接的内容清单和完成标准
数据与安全	数据处理边界、留存、合规责任
知识产权	通用组件的归属（这条直接关系第 31 章的资产化）

最后一条经常被忽略，但它决定了你能不能把项目里的通用能力带走。

如果合同写的是"所有交付成果归甲方所有"，那第 31 章的复利循环就不成立了。

我的建议是在合同里区分：客户特有的业务逻辑和数据归客户，通用组件和方法保留使用权。这件事要在签合同同时谈，不能事后补。

「明确不做」这一栏

这是 SOW 里我认为性价比最高的一栏。

写清楚哪些不在本期范围：哪些系统不接、哪些场景不覆盖、哪些异常走人工、第 14 章那七类问题里哪几类本期不处理。

它的作用不是推责任，是让双方对“完成”的理解一致。

大部分交付纠纷的根源，是双方对完成的定义不同，而这个差异在签字时就存在，只是没人写下来。

一个判断

这一章讲的所有东西，都在解决一个问题：**让项目的边界可验证。**

第 2 章讲的顺序是让系统正确，这一章讲的是让项目能收尾。

两者缺一个，另一个都没有意义。技术做对了但项目收不了尾，团队会被拖死；项目收尾了但系统不对，客户不会有第二次。

下一章讲甲方依赖，我认为它是这一篇里最该单独拿出来讲的一节。

§25 甲方依赖：项目失败最常见的非技术原因

这一章可能是全书最不性感、但最能救项目的一章。

MIT 那份报告把数据就绪度列为失败主因之一。在现场，"数据没就绪"往往不是技术问题，是**没人负责去开那个权限**。

什么是甲方依赖

指的是项目推进必须由客户提供、而交付方无法自行获得的东西。

四类：

人。业务负责人、数据/IT 对接人、一线受访者、验收人。

数据与访问。测试环境账号、只读权限、接口文档、样本数据、生产环境的部署条件。

决策。第 17 章那份待确认清单的答案、规则冲突的裁决、流程变更的批准。

审批通道。安全评审、合规审查、上线审批的排期。

为什么必须写进合同

因为它们的**延迟成本**，默认会算在交付方头上。

一个很常见的情形：账号申请走了六周流程，项目停了六周，最后客户问"为什么延期了"。

如果 SOW 里没写这一条，你只能自认。写了，这就是一次合法的工期顺延。

我的判断是：**甲方依赖这一节，是 SOW 里唯一能保护交付方的部分**。

其他条款基本都在约束交付方。

怎么写

每一项要有四个要素。

要素	例子
具体内容	A 系统订单表的只读权限
责任人	客户方某个岗位（有名字更好）
截止时间	项目启动后第 X 天
未按时提供的后果	相关阶段工期顺延，顺延天数等于延迟天数

第四条是关键。

没有后果的依赖清单，等于一份愿望清单。

写清楚后果不是为了追责，是为了让客户内部知道这件事有优先级。很多时候延迟不是因为不配合，是因为对接人不知道这件事卡着整个项目。

三个最容易卡住的依赖

第一，生产环境的访问权限。

测试环境通常好办，生产环境要走安全审批。这个流程在大企业里可能要一个月以上。

对策是在项目启动时就发起申请，不要等到需要用的时候。

第二，一线人员的时间。

第 17 章的现场观察需要一线配合，而一线有自己的 KPI。

对策是让业务负责人明确安排，而不是让 FDE 自己去约。**这件事必须由客户内部的人推动。**

第三，待确认事实的答案。

第 17 章和第 19 章都提过这份清单。它的答案往往涉及跨部门协调，客户内部可能本来就没有共识。

对策是把清单分级：哪些影响本期范围（必须在某个日期前给答案），哪些不影响（记入风险清单，命中时走人工）。

依赖的可视化

我建议在项目里维护一张公开的依赖状态表，每周同步给客户。

依赖项	责任人	承诺日期	状态	影响
...	...	...	已提供 / 进行中 / 逾期	逾期会影响哪个里程碑

这张表的作用不是施压。

它的真正价值是：**让客户业务负责人看到自己团队卡在哪。**

多数情况下业务负责人是有权推动的，他只是不知道有东西卡着。

一条经验判断

第 12 章那份技术尽调清单里说过：任何一项答不上来，工期都要往后加。

这里给一条更具体的：**如果启动一个月后，甲方依赖清单里还有超过三分之一没有兑现，这个项目的风险已经很高了。**

这时候我认为正确的动作不是加班赶进度，是把问题正式提到业务负责人层面，重新评估范围和时间。

继续闷头做的结果，通常是最后一起延期，然后责任落在交付方。

甲方依赖和第 15 章的关系

第 15 章的七道门里，“负责人”和“数据”两道，检验的就是甲方依赖能不能兑现。

筛选阶段没验证的依赖，会在执行阶段变成风险。

所以第 23 章说筛选客户时要用实际动作验证——真的拿到一份样本数据，而不是听答复。

拿到了，说明这条路径是通的。拿不到，说明这个客户内部的协调能力有问题，而这个问题在项目里只会更严重。

下一章讲变更和验收。

§26 变更管理与验收证据

企业 AI 项目的需求一定会变。

原因不是客户善变，是第 17 章那个过程本身就在制造变更——你把真实流程摸清楚了，客户才第一次看清自己的现状，然后想法就变了。

所以变更不是异常，是这类项目的常态。要做的是给它一条通道。

三类变更，处理方式不同

类型	例子	处理
认知修正	调研发现实际流程和描述不符	不算变更，改 Outcome Contract 并重新签
范围新增	客户想加一个场景或一个系统	走正式变更，评估影响，重议工期预算
细节调整	某个规则的阈值改一下	记录即可，不走流程

第一类最容易被误处理。

调研发现真实情况和当初的假设不同，这不是客户加需求，是双方都不知道的事实浮出来了。

这时候正确的动作是回到 Outcome Contract 重新对齐，而不是硬扛着按原计划做。

按原计划做的结果是做出一个不符合实际的系统，验收时才发现，那时候成本高得多。

变更流程要简单

我见过一些团队把变更流程做得很重，结果是没人走，改动全部私下发生。

我认为有效的变更流程只需要三步：

写下来改什么、为什么改。评估对范围、工期、预算的影响。双方确认。

关键不是流程复杂度，是**有没有留下记录**。

记录的价值在验收时体现：三个月后没人记得当初为什么加了这个功能、当时说好工期加了两周。

一个我认为有用的做法：变更预算

在合同里预留一定比例的变更额度（比如总工作量的百分之十五），用于小范围调整，不走正式流程。

超出这个额度才启动正式变更。

好处是双方都不用为小事扯皮，同时又有一个明确的边界。

坏处是这个额度用完之后，客户会觉得"以前都能改，现在为什么不行"。所以额度的消耗要透明，定期同步。

验收：证据比结论重要

第 16 章说过 Outcome Contract 是验收的唯一依据。

这里讲证据的形式。

验收项	证据形式
业务指标达标	对比基线的实际数据，覆盖达标观察期
系统稳定运行	监控数据：可用性、延迟、错误率
评估集通过	第 21 章的分类评估结果，各类分别达标
采用情况	使用人数、使用频次、建议采纳率
异常处理有效	异常发生时的处理记录，人工介入是否及时
交接完成	第 27 章的交接清单，客户方签收

第一项和第四项要放在一起看。

指标达标但没人用，通常意味着指标选错了。

比如"处理时长下降"达标了，但实际上是因为大家绕过系统直接手工处理——第 22 章讲的逃逸率就是在防这个。

验收会怎么开

参加的人必须包括业务负责人。理由在第 16 章说过。

我建议的顺序是：先看数据，再看现场，最后谈遗留。

先看数据。 把 Outcome Contract 里的每一条逐项对照，达标的、未达标的都摆出来。

再看现场。 找一线操作员实际跑几个案例，包括异常场景。这一步经常能暴露文档上看不出来的问题。

最后谈遗留。 哪些是本期明确不做的（对照 SOW 那一栏），哪些是发现的新问题（进下一期），哪些是缺陷（本期修）。

第三步的分类要在会上当场做完，不要留到会后。

未达标怎么办

这是验收里最难的部分，也是必须提前在 SOW 里定好规则的部分。

要区分两种情况。

一种是甲方依赖未兑现导致的。第 25 章那份依赖状态表在这里派上用场。如果某个指标不达标是因为数据一直没给，责任不在交付方。

另一种是系统本身的问题。那就要定：修复期多长、修复期间的付款怎么处理、修不好怎么办。

我认为最不该出现的是"再看看"。没有明确结论的验收会让项目无限期挂着，交付方的人力被锁死，客户也拿不到确定的东西。

验收和付款

具体条款不展开，但有一条我认为要坚持：**分阶段付款，且每个阶段的付款条件是可验证的产物，不是时间。**

比如诊断结束付一笔（对应诊断报告）、系统上线付一笔（对应上线并通过评估）、验收通过付一笔（对应达标观察期结束）。

按时间付款的问题是，它和实际进展脱钩。项目卡在甲方依赖上的时候，付款节点照样到，双方都尴尬。

下一章讲最后一步：怎么把这套东西真正交出去。

§27 上线培训、采用率与交接

第 22 章讲的是系统怎么放量，这一章讲的是人怎么接过去。

技术上的完成，不等于交付完成；验收通过，也不等于业务成功。

MIT 那份报告说 95% 的项目没有可衡量的损益影响。我认为其中相当一部分，系统是能跑的，只是没人用。

采用率是一个设计问题

采用率经常被当成培训问题——"多培训几次就好了"。

我不这么认为。**采用率主要是系统设计的结果，培训只能补一小部分。**

几个决定采用率的设计因素：

入口位置。 系统嵌在原有工作流里，还是要跳到另一个地方。第 13 章讲第二层需求时说过，让人跳出去生成再复制回来，基本没人会用。

默认状态。 是默认打开还是要主动开启。这个差别比大多数人以为的大。

失败时的成本。 AI 给的结果不对时，人是"改一下"还是"整个重来"。后者会让人放弃使用。

反馈通道。 用户觉得不对的时候，能不能一键报错。没有通道，不满会积累成弃用。

培训要讲什么

培训的重点不是操作步骤，是边界。

我认为要讲清楚三件事：

它能做什么、不能做什么。 明确说出哪些情况它处理不了，会转人工。这比夸大能力重要得多——第一次遇到它做不到的事而没有预期，用户的信任就崩了。

做错了怎么办。 怎么撤销、找谁、多久能处理。

怎么反馈。 觉得结果不对的时候，在哪里点、点了之后会发生什么。

第三条要真的有人处理。**如果反馈进了黑洞，第二次就没人反馈了，你也就失去了最重要的改进来源。**

交接清单

第 4 章的第五个问题问的就是这个：项目结束后谁维护。

交接不是给一份文档，是把几个具体职责移交出去，每一项都要有接手人。

交接项	内容	接手人
日常监控	看哪些指标、异常时怎么处理	客户运维或指定岗位
Context 维护	文档更新后同步 Registry、定期复核	客户业务方
规则变更	业务规则变了怎么改、谁批准	业务负责人
评估集维护	新故障转成用例、定期回归	交付方或客户技术
模型升级	谁负责重跑评估、验证约束是否还需要	双方约定
故障响应	分级、响应时间、升级路径	双方约定

第二项和第五项最容易漏。

第 19 章说过，上下文系统会腐化，而且没人会知道是从哪天开始错的。

第 10 章和第 11 章说过，模型升级后旧约束可能变成负担，需要重新评估。

这两件事如果没有接手人，系统会在几个月内悄悄退化，而且退化时没有报警。

让客户具备自主运营能力

第 1 章说过 AWS 的目标之一是让客户最终能独立运营。

我认为这不是客气话，而是这个模式能不能扩张的前提。

具体要移交的能力：

能自己改业务规则（因为规则写在配置里，不在提示词里——第 18 章）。

能自己判断系统是好是坏（因为有评估集和指标——第 21 章）。

能自己定位问题在哪一层（因为有第 22 章那张偏差分类表）。

知道什么情况需要找回交付方（明确的升级路径）。

前三条的前提，都是前面几章那些交付物真的做扎实了。

如果规则藏在提示词里、判断靠人工抽查、问题分不了类，那客户永远独立不了，你也永远走不掉。

支持期的边界

第 24 章说过报价要明确支持范围和期限。这里讲具体怎么划。

要写清楚的：

支持哪些内容（缺陷修复算，新需求不算）。响应时间怎么分级。支持期多长。支持期结束后怎么续。

我认为最重要的是把"缺陷"和"新需求"的界限写清楚。

界限的判断依据是 Outcome Contract 和 SOW：契约里承诺的行为没做到，是缺陷；契约里没写的，是新需求。

没有这个界限，支持期会变成免费的第二期开发。

交接完成的标志

我用三条来判断：

客户方在没有交付方参与的情况下，独立处理过一次真实故障。

客户方独立完成过一次规则变更，并跑通了评估。

监控和告警接进了客户自己的值班体系。

三条都做到，才算交出去了。

只签了一份交接确认单，不算。

Part 6 到这里结束。

下一篇用三个推演，把前面两篇的方法论完整走一遍。

本章引用

- [The GenAI Divide: State of AI in Business 2025](#), MIT Media Lab NANDA
- [AWS Forward Deployed Engineering for Partners](#)

Part 7 推演篇：把方法论走一遍

先说清楚这一篇是什么。

这三章不是真实客户项目的复盘。

我在首页说过这本书的依据，这里再强调一次：我没有几十个客户现场的一手经验，所以不会编造客户名、行业数据和项目结果来伪装成案例。

这三章是推演。用前六篇的方法论，对三类典型场景走一遍完整流程，重点展示每一步的交付物长什么样、判断依据是什么、在哪里会卡住。

它的用法是模板，不是案例。 你把自己的场景代进去，就知道该产出什么。

三个推演按第 13 章的层级递增：

推演	场景类型	主要落在第几层	重点展示
一	企业知识助手	第一层 信息获取	Context 治理
二	客服处理 Agent	第三到四层	工作流、人工接管、评估
三	跨系统执行 Agent	第五层 自主执行	权限、副作用、回滚

§28 推演一：企业知识助手

客户最初的说法

"我们内部资料太散了，员工找东西很费劲。想做一个知识库，能问答的那种。"

这是第 14 章第一类问题的典型表述：**没有可衡量的业务结果。**

第一步：把它问下去

按第 16 章那九个问题追。

谁在找？找什么？一天多少次？找不到的时候怎么办？现在平均要花多久？找错了会怎样？

追问后可能出现的情况是：这个需求其实包含好几个不同的东西。

新员工问制度（低频、答案稳定、错了影响小）。一线问产品参数（高频、答案会变、错了会给客户错误信息）。管理层问数据（要接系统，不是文档问答）。

三个需求的难度和风险完全不同，不能混成一个项目。

按第 15 章的七道门筛，第二个通常最值得先做：频率高、结果可衡量（查询耗时、答错率）、数据可获得、错误可恢复（人会核对再发给客户）。

第二步：Outcome Contract 长什么样

按第 16 章的骨架，关键几栏可能是这样：

范围：产品参数与政策类问题的内部查询

明确不做：客户直接使用（本期仅内部）、数据类查询、跨系统取数

结果：

目标状态改变：一线查询产品信息的平均耗时下降

衡量指标：单次查询平均耗时；答案被采纳后仍需二次核对的比例

当前基线：需要先测（当前无人统计）

达标观察期：连续 4 周

判定：

成功：命中知识库范围内的问题，给出带来源引用的正确答案

失败：给出无来源支撑的答案，或引用了已作废文档

部分成功：只能给出相关文档而无法直接回答 — 允许，计入"仅定位"类

风险边界：

单次错误代价：一线据此答复客户，可能造成承诺偏差

必须拒绝：涉及价格授权、合同条款解释的问题

注意"必须拒绝"那一栏。

第一层需求看起来风险低，但一旦答案会被转述给客户，风险就不低了。

第三步：这个场景真正的难点

不是检索。是第 14 章的第二类问题：知识散、冲突、过期。

第 17 章的 Context Audit 在这个场景里是主要工作量。可能会发现：

同一份产品文档存在多个版本，散在不同位置，没人知道哪份现行。

一部分参数在文档里，一部分在系统里，两边对不上。

有些规则从来没写进文档，只在几个资深同事那里。

有大量已经作废但没删的资料。

第 10 章说过：模型没有判断权威性的能力，检索分数和权威性无关。

所以这个项目的核心交付物是 Context Registry，不是检索系统。

第四步：Registry 的关键列

按第 19 章的模板，这个场景里最吃紧的三列：

权威级别。 系统里的结构化参数标高，正式发布的文档标中，个人整理的资料标低。冲突时高压中。

有效期。 产品参数类的信息要有失效时间，过期的不再进上下文，或者进的时候带上"此信息可能已过期"的标记。

状态。 已确认 / 待确认 / 已废弃。废弃的要真的从索引里移除，不能只是标记。

第五步：评估集里最该有的用例

按第 21 章的七类：

上下文冲突——构造两份说法不同的产品文档，检查系统是否按权威级别选择，以及是否在答案里说明了依据。

信息缺失——问一个知识库里没有的参数，检查是否明确说"没有找到"，而不是编造一个合理的数字。

必须拒绝——问"这个客户能不能给八折"，检查是否拒绝并转人工。

边界——问一个知识库覆盖范围边缘的问题，检查是否会强行回答。

第二类是这个场景里最关键的。**第一层需求里，编造是最高频也最难发现的失效。**

因为编造出来的答案格式正确、看起来合理，人如果不核对就不会发现。

第六步：怎么放量

按第 22 章的七级，这个场景通常只需要走到第三级：只读建议。

系统给答案和来源引用，人自己判断用不用。

这一级的关键指标是采纳率，不是准确率。人有多少比例直接用了系统给的答案，比模型自评的准确率更接近真实价值。

这个推演里最容易踩的坑

第一，把它当成简单项目。 因为技术栈简单，容易低估 Context Audit 的工作量。实际上这部分可能占全项目一半以上。

第二，追求覆盖率。 想把所有文档都放进去。第 10 章说过，上下文是有限资源，文档越多噪音越多。宁可先覆盖一个明确的范围，做准。

第三，不带来源。 答案不给来源引用，人就无法核对，也就无法建立信任。**在第一层需求里，来源引用比答案本身更重要。**

第四，没有反馈通道。 第 27 章说过，用户觉得不对时如果不能一键报错，不满会积累成弃用。

可以沉淀什么

按第 31 章的分类：

客户特有的是文档结构、术语表、权威规则。

可复用的是 Context Registry 模板、冲突检测的方法、"信息缺失"和"必须拒绝"这两类评估用例的构造方式、来源引用的展示形式。

下一个推演的复杂度上一个台阶。

§29 推演二：客服处理 Agent

客户最初的说法

"客服人力不够，想让 AI 把简单工单直接处理掉。"

比上一个推演具体，但仍然缺三样：哪些算简单、处理到什么程度、错了怎么办。

第一步：拆开这个需求

第 13 章说过，客户描述的层级和实际需要的层级经常不一致。

"直接处理掉"听起来是第五层（自主执行），但拆开看，一张工单的处理其实包含好几段：

读懂客户问什么。判断属于哪一类。调取相关信息（订单、账户、历史记录）。决定怎么答复。执行动作（回复、改状态、发起退款、转人工）。

前四段是第三层（分析判断）和第四层（流程协同），最后一段才是第五层。

而真正耗时的往往是中间三段，不是最后那一下。

按第 2 章的顺序，这个判断要靠第 17 章的现场观察得出——看客服处理二十张工单，时间实际花在哪。

第二步：范围收缩

按第 24 章的四个条件切。

一个可能的切法：**只处理某一类规则明确的工单，且只做到"生成答复草稿 + 附上依据"**，人点确认后发出。

这样切之后：

频率够（这类工单占比高）。结果可衡量（单张处理时长、草稿采纳率）。数据可获得（工单系统 + 订单系统只读）。错误可恢复（人在发出前会看一眼）。

第五层的部分留到后面。第 13 章说过，层级可以爬，但不能跳。

第三步：这个场景的核心是流程契约

上一个推演的核心是 Context，这一个的核心是第 18 章的 Workflow Contract。


因为客服流程有大量分支和异常，而 SOP 里通常只写了正常路径。

现场观察会发现的异常可能包括：客户描述不清、订单信息与客户描述不符、涉及多个订单、客户情绪激烈、请求超出政策范围、需要跨部门协调、系统查不到记录。

这些在人手里是自然处理的，AI 接手后会突然变得可见。

第四步：状态机和异常矩阵

按第 18 章的骨架，这个场景的状态机大致是：



"已修改发出"这个状态必须有。

第 18 章说过，如果系统不支持"修改后批准"，人就会跳出系统去手工处理，流程数据就断了。

而且这个状态是最有价值的数据来源——人改了什么，就是系统还差什么。

异常矩阵按第 18 章的分类方式：

异常	类别	处理
客户描述不清	需要补信息	生成澄清问题，转待补充
订单信息与描述不符	需要人判断	转人工，附上两边的差异
涉及多个订单	需要人判断	本期不处理，直接转人工
客户情绪激烈	需要人判断	转人工，标记优先级
超出政策范围	必须拒绝	转人工，不生成草稿
系统查不到记录	未知	保守停止，报警

"涉及多个订单"这一行体现的是第 24 章的范围收缩——**明确写出本期不处理，比勉强处理要好。**

第五步：决策规则要写在外面

第 18 章那条实践在这个场景里特别重要。

哪类工单算高风险、什么金额以上必须人工、哪些客户等级有特殊政策——这些都是条件判断，应该写成显式配置。

理由是业务方要能自己改。

客服政策变化很频繁。如果每次调整都要改提示词、重新测试、重新发版，这个系统很快就跟不上业务了。

第 27 章讲的"让客户具备自主运营能力"，第一条就是能自己改规则。

第六步：评估集

这个场景的评估比上一个复杂，因为要检查的是状态转移是否正确，不只是文本质量。

按第 21 章的七类：

正常——各类工单的典型案例，检查分类是否正确、草稿是否引用了正确的订单信息。

边界——金额刚好在人工审批线上线下的案例。

信息缺失——客户只说了"我的订单有问题"，检查是否生成澄清问题而不是猜测。

上下文冲突——客户说的和系统记录不一致，检查是否转人工而不是选一边相信。

权限越界——用一个客服的身份查另一个区域的订单，检查是否拒绝。

必须拒绝——客户要求超出政策的补偿，检查是否转人工而不是自行答应。

下游失败——工单系统写入超时，检查是否重复发送答复。

最后一类在这个场景里代价很高。**同一条答复发两次给客户，是真实可见的事故。**

所以第 20 章讲的幂等在这里是硬要求。

第七步：放量路径

按第 22 章：

离线重放历史工单 → 影子运行（生成草稿但不给人看，只做对比）→ 只读建议（草稿给客服看）→ 人工确认后发出 → 某几类低风险工单自动发出。

每一级的门槛要按工单类型分别设，不看整体平均。

第 21 章说过，平均分会掩盖问题。整体 95% 的系统，可能在"必须拒绝"那类上只有 60%。

这个推演里最容易踩的坑

第一，用整体准确率作为上线门槛。 上面说过。

第二，忽略采纳率和逃逸率。 草稿准确率很高，但客服嫌改起来麻烦，全部自己重写——第 22 章讲的逃逸率就是在测这个。

第三，把异常全部丢给人工。 转人工的比例过高，自动化价值就没了。要按第 22 章的偏差分类逐类分析，哪些是可以收回来的。

第四，没有留"人改了什么"的数据。 这是最可惜的一种浪费，因为这份数据是改进系统最直接的原料。

可以沉淀什么

客户特有的是工单分类体系、政策规则、话术风格。

可复用的是这套状态机骨架、异常分类方式、"修改后批准"的实现、按类型分别设门槛的评估框架、工单系统的连接器。

下一个推演进入第五层。

§30 推演三：跨系统执行 Agent

客户最初的说法

"我们希望 AI 能自动完成整个流程，从发现问题到处理完，不用人管。"

第 13 章的第五层，自主执行。

以运营类场景为例：系统监测到某个业务指标异常，判断原因，生成处理方案，然后直接在几个系统里执行——改配置、发通知、生成单据。

第一步：先判断该不该做

按第 15 章的七道门。

这类需求最容易卡在两道：**可恢复**和**负责人**。

可恢复这一门：执行动作会不会不可撤销。发通知发出去了收不回来，单据生成了要走冲销流程。

负责人这一门：谁来批准让 AI 自动改生产系统的配置。这个人通常比业务负责人级别更高。

如果这两道过不了，正确的动作是降层。

降到第四层：AI 完成监测、判断、方案生成和材料准备，最后的执行动作由人点一下。

价值可能只剩一半，但项目能活下来，而且这一半的价值也是实的——第 29 章那个推演已经说明，耗时往往在前面几段，不在最后那一下。

第二步：假设条件满足，Outcome Contract 怎么写

第 16 章那份骨架里，这个场景的"风险与边界"部分是重点：

风险与边界：

单次错误代价：错误配置可能影响线上业务；错误通知会到达外部

不可恢复的动作：

- 对外发送的通知（发出即不可撤回）
- 已进入财务流程的单据（需走冲销）

可恢复的动作：

- 内部配置变更（有变更记录，可回滚）
- 内部工单状态变更

必须人工批准：所有不可恢复的动作，无一例外

必须拒绝：影响范围超过阈值的批量操作

"所有不可恢复的动作必须人工批准，无一例外"这一条我认为不能妥协。

第 14 章说过：如果一个动作错了没法撤销，它就必须有人工检查点，不管模型准确率多高。

准确率再高也不是零。而不可恢复的错误，一次就够。

第三步：这个场景的核心是 Agent Harness

前两个推演的核心分别是 Context 和 Workflow，这一个是第 20 章的 Harness。

因为这里的每一个动作都会真的改变外部系统。

要逐项落实的：

工具契约。 每个可执行的动作都要有明确定义：参数校验、副作用说明、幂等保证、失败语义。

幂等。 第 20 章说过这是底线。这个场景里尤其重要，因为多步流程的重试是必然发生的。

如果下游系统不支持幂等键，那这个动作就不能自动重试，只能转人工。

副作用清单。 每一步执行前记录"我将要改什么"，执行后记录"我改了什么"。

这份清单是回滚的唯一依据。第 18 章说过它是回滚设计的前提。

身份与权限。 第 12 章的问题在这里最尖锐：Agent 用什么身份去改生产配置，这个权限谁批的，审计日志记在谁名下。

这个问题必须在方案阶段就拿给客户的安全部门确认。等上线前一周提出来，改架构的成本最高。

第四步：多步流程的成功率问题

第 9 章说过，单步 95% 的成功率，十步串起来只剩六成。

这个场景的流程通常就是十步左右。所以要在设计上处理：

减少步数。 能合并的合并，能用确定性代码做的不要交给模型。

每步验证。 每一步执行后检查实际状态，而不是相信调用返回。

关键节点核对。 第 20 章提过，长流程中途插入一次核对，确认当前进展还在解决最初那个问题。

总步数上限。 超过上限就停下转人工，而不是继续尝试。

第 20 章引的那两个失效模式在这里最危险：过度乐观（为了让任务显得完成而降低标准），以及执行压力下的实现漂移（长流程里慢慢偏离原定计划）。

第五步：评估要检查最终环境状态

第 21 章那条原则在这个场景里是命脉：

不能相信 Agent 说"已完成"，要去目标系统里查实际状态。

评估用例的断言对象是：配置是否真的改了、通知是否真的发出、单据是否真的生成、以及有没有产生预期之外的副作用。

最后一条容易漏。**要检查的不只是"该做的做了"，还有"不该做的没做"。**

具体做法是在测试环境里对比执行前后的完整状态快照。

第六步：回滚设计

第 12 章说过：能回滚代码，不等于能回滚业务后果。

这个场景必须提前设计的：

每类动作的撤销方式是什么（自动撤销 / 手工撤销 / 无法撤销）。

发现错误后，怎么找到所有受影响的对象（靠副作用清单）。

谁有权触发回滚，触发条件是什么。

回滚期间业务怎么运转（人工流程是否还可用）。

第 22 章说过，有些项目上线后把人工流程的工具和岗位撤了，出问题就退无可退。

至少在达标观察期结束前，人工流程要保持可用。

第七步：放量路径最长

按第 22 章的七级，这个场景每一级都要认真走。

尤其是影子运行那一级——让 Agent 完整跑一遍但不真正执行，把"它想做什么"记录下来，和人的实际处理对比。

这一级能暴露的东西最多，成本却是零。**我认为这个场景里影子运行至少要跑一个完整的业务周期。**

从"人工批准后执行"到"部分自动执行"的那一步，要按动作类型逐个放开，而不是整体放开。

放开顺序按错误代价排，不按发生频率排。

这个推演里最容易踩的坑

- 第一，一开始就要第五层。** 前面反复说过，跳级的代价是第一次出错就可能终结项目。
- 第二，幂等靠"应该不会重复"。** 第 20 章说过，重试是必然会发生的。
- 第三，把人工审批做成一个按钮。** 第 20 章说过，审批人要看到足够信息才能判断：当前状态、Agent 的建议、依据、批准后会发生什么。信息不够，人就会闭眼点确认，审批形同虚设。
- 第四，没有副作用清单。** 出事时找不到所有受影响的对象，只能全量排查。
- 第五，撤了人工流程。** 上面说过。

三个推演的对比

	推演一 知识助手	推演二 客服 Agent	推演三 执行 Agent
主要层级	第一层	第三到四层	第五层
核心交付物	Context Registry	Workflow Contract	Agent Harness
最大工作量	Context Audit	异常矩阵与状态机	权限、幂等、回滚
最危险的失效	编造	重复执行、逃逸	不可恢复的错误动作
放量终点	第三级 只读建议	第五级 部分自动	第七级 有条件自治
上线前最该验的	来源引用是否可核对	各类型分别达标	影子运行跑满一个周期

这张表是这三章最有用的部分。

它说明同样一套方法论，在不同层级的场景里，重心会转移到不同的地方。

Part 7 到这里结束。下一篇讲怎么让这些经验不留在单个项目里。

Part 8 资产篇：让下一单不从零开始

前七篇讲的是怎么把一个项目做成。

这一篇讲的是怎么让第二个项目比第一个便宜。

这是 FDE 模式和传统驻场交付的分界线，也是这本书最后要落的地方。

§31 复利循环：把项目变成能力

先看清楚这件事有多重要

第 3 章讲过 Palantir 的 Dev / Delta 划分，以及那条虚线：反复出现的差量要被吸收进通用产品。

第 4 章的六个问题里，有三个（代码进哪个仓库、岗位归谁管、问题怎么进产品）都在问这条虚线。

第 1 章提过 AWS 用了 Delivery Harness 这个词，把领域本体、Context Graph、评估框架、MCP Server、Agent 运维工具装进同一套交付体系，每做完一个客户就厚一层。

三个地方指向同一件事：**如果每一单都从空白开始，FDE 就是昂贵的人力外包。**

而且成本还在上升，因为这个岗位要求的能力比传统实施顾问高。

每个项目结束时，把产出分成两堆

这是最关键的一个动作，而且必须在项目还热的时候做，不能等三个月后。

类别	内容	去处
客户特有	业务规则、术语、权限模型、专属集成、话术风格	留在客户项目里
可复用	连接器、工具契约、Context 模板、评估用例类型、异常分类、状态机骨架、部署清单	进资产库或产品

分类的判断标准很简单：**换一个客户，这个东西还成不成立。**

产品参数表不成立，是客户特有的。"信息缺失时不许编造"这一类评估用例的构造方式成立，是可复用的。

六种最值得沉淀的东西

按我的判断排序。

第一，评估用例的类型库。

不是具体用例，是类型和构造方法。第 21 章那七类，每一类怎么造、断言什么，这套方法在所有项目里通用。

我认为这是价值最高的资产，因为它直接决定了新项目能不能快速建立判据——而判据是第 2 章那个顺序里最容易被跳过的一环。

第二，连接器和 MCP Server。

企业常见系统就那么几类。同一个系统接第二次，不该重写。

第三，Context Registry 模板和权威规则。

第 19 章那张表的结构是通用的。第二个项目直接拿去填，省下的不只是时间，还有"想不到要问这一列"的风险。

第四，状态机骨架和异常分类。

第 18 章和第 29 章的那套骨架，换个业务改改就能用。异常的五种分类（可自动恢复、需补信息、需人判断、必须拒绝、未知）几乎是通用的。

第五，实施流程本身。


也就是第 2 章那个顺序，加上每一步的产物和检验方式。这套东西写下来，新人上手会快很多。

第六，故障库。

每一次线上故障，除了转成回归用例，还要记下它属于第 22 章偏差分类表的哪一类、最后怎么修的。

故障库是新人最快的学习材料，也是判断"这个坑我们踩过没有"的唯一依据。

循环怎么转起来



注意最下面那条：**反复出现的可复用资产，最终要进产品。**

资产库只是中转站。如果一个东西在五个项目里都用到了，它就该变成产品能力，而不是继续躺在资产库里靠人复制粘贴。

第 3 章说过，这条路径通不通，取决于组织归属。

三个会让循环转不起来的原因

第一，合同把所有成果都给了客户。

第 24 章说过，SOW 里的知识产权条款要区分：客户特有的归客户，通用组件保留使用权。

这件事签合同时不谈，事后补不上。

第二，没有复盘的时间。

项目一结束就开下一个，复盘永远排不上。三个月后再回忆，细节已经丢了。

我的建议是把复盘写进项目计划，作为项目的最后一个里程碑，而不是"有空再做"。

第三，资产没人维护。

资产库最常见的结局是：建了、放了几样东西、然后腐化。半年后没人敢用，因为不知道还能不能跑。

对策是给每份资产一个负责人和一个"最后验证时间"——和第 19 章 Context Registry 的思路一样。

没有维护机制的资产库，和没有资产库的区别不大。

怎么衡量循环转得好不好

我认为有几个可以量化的信号：

同类型项目的第二次交付周期，比第一次短多少。

新项目里可复用资产的占比是多少。

上一年沉淀的资产里，有多少在今年被实际用过（没被用过的说明抽象错了）。

有多少资产已经毕业进了产品。

最后一个**是终极指标**。因为它意味着这部分工作不再需要 FDE 手工做了。

一个提醒：不要过早抽象

前面讲的都是要沉淀，这里说反面。

一个东西只出现过一次，不要抽象。

过早抽象的代价是：抽象出来的东西带着第一个客户的假设，到第二个客户那里发现不适用，改起来比重写还麻烦。

我的经验判断是：**同一个东西在两个客户那里出现过，才考虑抽象；三次以上，考虑进产品。**

在此之前，先老实复制粘贴。复制粘贴的成本是可见的，错误抽象的成本是隐藏的。

下一章是这本书的最后一章，讲什么时候不需要 FDE。

本章引用

- [AWS Forward Deployed Engineering for Partners](#)
- [Dev versus Delta: Demystifying Engineering Roles at Palantir](#)

§32 什么时候不需要 FDE

一本讲 FDE 的书，最后一章讲什么时候不需要它。

这不是谦虚。第 3 章说过，责任边界如果只往外扩不往里收，这个岗位会被拖垮。

一个方法论如果没有适用边界，它就不是方法论，是推销。

三种不需要 FDE 的情况

第一，标准产品能解决的。

如果一个需求可以用现成的 SaaS 直接满足，配置一下就能用，那不需要 FDE。

判断方法：把第 14 章那七类问题过一遍。如果七类里有五类以上不成立——上下文不复杂、流程标准、没有跨系统写入、错误代价低——那这个场景的差量很小。

第 3 章讲的 Delta 概念，说的就是差量才是工作量。差量小，就不需要现场工程师。

第二，企业自己能做的。

有成熟内部技术团队、业务和技术在同一个组织里、数据和权限都是自己的。

这种情况下企业自建的效率可能更高，因为第 25 章那些甲方依赖问题不存在。

MIT 那份报告里企业自建只有 33% 进生产，但那是平均数。有能力的团队不在那个平均数里。

第三，问题不在 AI 上。

现场经常遇到的情况是：客户觉得某个环节效率低，想上 AI，但真实原因是流程设计有问题、或者两个部门的职责重叠、或者某个系统本来就该被替换。

这时候上 AI 是在给一个坏流程加自动化，会让它更难改。

FDE 能做的是在诊断阶段把这个判断说出来。第 23 章说过，诊断报告里“建议不做的”那部分要认真写。

什么时候 FDE 会不再需要

这是个更长期的问题，我给的是判断，不是预测。

有几件事正在往那个方向走。

产品在吸收差量。 第 31 章说的那条路径：反复出现的资产会进产品。进得越多，需要现场手工做的越少。

工具在降低门槛。 Coding Agent 让“能自己做出来”这件事的成本下降了。第 6 章讲产品经理转型路径时提过这一点。

方法在标准化。 这本书写的这些东西，如果最后变成大家都会的常识，那它的稀缺性就没了。

但我认为有几件事短期内不会消失。

企业内部的隐性知识不会自动变成文档。 第 17 章讲的那个“制度写的和实际做的之间的差值”，需要人去现场挖。

跨部门的规则冲突需要人去协调。 第 19 章那份待确认清单，答案要靠人去要。

责任需要有人承担。 第 3 章说的那个“完成信号在客户那边”，这件事没法自动化。

所以我的判断是：FDE 的技术部分会被工具吃掉很多，但责任部分不会。

这本书最后想说的

回到第 1 章那个数字。

MIT 那份报告说，企业投进生成式 AI 的三四百亿美元里，95% 没有产生可衡量的损益影响。归因是数据就绪度、 workflow 集成、缺少反馈闭环。

这三条里没有一条是模型问题。

这本书写了三十二章，讲的其实就是怎么把这三条补上：

数据就绪度，对应第 17 章的 Context Audit 和第 19 章的 Context Registry。

workflow 集成，对应第 18 章的流程契约、第 20 章的 Harness、第 22 章的放量路径。

反馈闭环，对应第 21 章的评估集、第 22 章的偏差分类、第 31 章的资产化循环。

而把这三件事串起来的，是第 2 章那个顺序：事实先于结果，结果先于判据，判据先于系统，验证先于放量。

这个顺序不复杂，难的是在没有可展示成果的那几周里顶住压力，不跳过它。

第 2 章说过，这是我认为 FDE 真正难的地方。它需要的不是更强的技术。

模型已经准备好了。

现在缺的是理解企业的人。

本章引用

- [The GenAI Divide: State of AI in Business 2025](#), MIT Media Lab NANDA

附录

这一部分是可以直接拿到现场用的表和清单。

正文里散落的检查项在这里集中一遍，用的时候不用翻书。

附录 A 企业 AI 需求诊断表

配合第 13、14、15 章使用。每个候选场景填一份。

场景基本信息

项	内容
场景名称	
提出人 / 部门	
客户的原始表述	原话记录
发生频率	每天 / 每周多少次
当前由谁完成	岗位与人数
单次耗时	

分层判断（第 13 章）

项	内容
客户以为它在第几层	
实际需要第几层	
建议第一阶段做到第几层	
三者不一致的地方	需要做预期管理的点

七道门（第 15 章）

门	判断	结论
1 频率		通过 / 不通过
2 结果可衡量	指标是什么，现在多少	
3 数据可获得	实际拿到样本了吗	
4 流程稳定	近半年改过几次	
5 错误可恢复	撤销方式	
6 有业务负责人	姓名与权限	
7 验证周期	多久能拿到真实数据	

七类问题标记（第 14 章）

#	问题类别	是否存在	本期处理
1	价值不清		
2	上下文碎片化		
3	流程不可计算		
4	工具不可控		
5	质量不可证明		
6	错误会传播		
7	无法复制		

结论

建议做 / 建议缓 / 建议不做，以及理由和补齐条件。

附录 B Outcome Contract 模板

配合第 16 章使用。控制在两页以内。

Outcome Contract: [场景名]

版本： 日期：

一、范围

本期处理：

本期明确不处理：

二、触发

触发条件：

不触发的情况：

三、结果

目标业务状态改变：

衡量指标：

当前基线： 测量方式： 测量时间范围：

本期目标值：

达标观察期：

四、判定

成功：

失败：

部分成功： 处理方式： 谁接手：

五、风险与边界

单次错误代价：

不可恢复的动作：

可恢复的动作及撤销方式：

必须人工批准的动作：

必须拒绝的请求类型：

六、责任

业务负责人（有权改流程和验收）：

数据 / IT 对接人：

交付方负责人：

七、结束

本期验收条件：

验收证据形式：

上线后支持范围与期限：

签字：业务负责人 _____ 交付方 _____

附录 C Context Registry 模板

配合第 19 章使用。每个信息源一行。

ID	名称	内容类型	物理位置	访问方式	负责人	权威级别	有效期	更新频率	权限范围	注入方式	已知冲突	状态
		事实/规则/术语/模板		API/直连/导出/人工		高/中/低				常驻/按需/不注入		已确认/待确认/已废弃

权威级别定义

高：由明确责任人维护，是这类信息的唯一正式出处。 中：正式文档，但可能滞后于实际执行。 低：有参考价值，不能单独作为依据。

冲突规则：高压中，中压低。同级冲突走待确认清单，找负责人拍板。

配套：待确认事实清单

ID	问题	涉及部门	影响本期范围	负责人	承诺答复日期	结论
----	----	------	--------	-----	--------	----

附录 D 生产上线检查清单

配合第 20、21、22 章使用。逐条勾选，任何一条未完成都不建议进入自动执行。

契约层

- ☐ Outcome Contract 已由业务负责人签字
- ☐ 基线数字已测出，测量方式可复现
- ☐ 本期不做的部分已写进 SOW
- ☐ 状态机的每个终态都能对应到契约里的成功/失败/部分成功

上下文层

- ☐ Context Registry 完整，权威级别、有效期、权限范围三列无空缺
- ☐ 冲突规则已进系统（不是只写在文档里）
- ☐ 待确认清单已有结论，未决项在系统里走人工
- ☐ 已废弃的资料真的移出索引

Harness 层

- ☐ 每个工具都有契约，参数在调用前校验
- ☐ 所有改变外部状态的动作都有幂等保护，或明确不重试
- ☐ 状态可持久化，失败能从断点恢复
- ☐ 副作用有记录，可逐条对应到撤销方式
- ☐ Agent 的身份和权限有书面确认，合规部门看过
- ☐ 所有需人批的动作都有接管点，接管人能看到足够信息
- ☐ 支持"修改后批准"
- ☐ 有循环次数和总步数上限
- ☐ 所有决策路径可从日志还原

评估层

- ☐ 评估集覆盖七类用例，后四类每类不少于约定数量
- ☐ 断言对象是业务状态，不是模型输出文本
- ☐ 技术基线已记录
- ☐ 上线门槛按类型分别设定，不看平均

运营层

- ☐ 影子运行已跑满约定周期
- ☐ 偏差已分类，不是全部靠改提示词处理
- ☐ 监控包含采用率、采纳率、人工介入率、逃逸率
- ☐ 回滚方案明确，人工流程仍可用
- ☐ 告警接入客户值班体系

交接层

- ☐ 六项交接职责都有接手人（监控、Context、规则、评估、模型升级、故障）
- ☐ 客户方独立处理过一次真实故障
- ☐ 客户方独立完成过一次规则变更并跑通评估

- ☐ 支持范围里"缺陷"和"新需求"的界限已写明

附录 E 指标体系

配合第 21、22、26 章使用。分五层，从技术到业务。

层	指标	说明	危险信号
一、系统	可用性、P95 延迟、错误率、单次成本	基础运行状况	高峰期延迟劣化
二、质量	各类用例准确率、误操作率、拒绝准确率	按第 21 章七类分别看	只看平均分
三、协作	人工介入率、建议采纳率、审批耗时	人机配合是否顺畅	介入率过高或过低
四、采用	使用人数、使用频次、逃逸率	有没有人真的在用	逃逸率上升
五、业务	Outcome Contract 里的指标 vs 基线	最终价值	达标但采用率低

看法

第二层和第五层要一起看。质量达标但业务指标没动，说明场景选错了。

第四层的逃逸率最容易被忽略，但它最诚实——人绕过系统的比例，说明系统在真实工作里好不好用。

附录 F 偏差分类速查

配合第 22 章使用。线上出现 bad case 时，先分类再动手。

偏差表现	归属	修法	章节
缺少某条信息	Context	补 Registry、改注入策略	§19
用了过期或错误的信息	Context	改权威级别、加有效期	§19
规则理解错	Workflow	规则从提示词移到显式判断	§18
状态流转错	Workflow	补状态定义和转移条件	§18
工具调用参数错	Harness	加参数校验	§20
重复执行	Harness	加幂等	§20
该转人工没转	Harness	补接管点触发条件	§20
模型确实做不到	范围	划出去交人工，改契约	§16

纪律：每加一条约束，记录它解决的是哪个具体 bad case。否则三个月后没人敢删。

附录 G 六个问题：判断真 FDE

配合第 4 章使用。面试或团队自查都可以用。

问题	在问什么	危险信号
你写的代码进哪个仓库	有没有产品化出口	每客户独立仓库
这个岗位归谁管	考核什么	挂交付中心，考核回款
项目结束的标准是什么	对什么负责	验收单签字
现场问题怎么进产品	反馈闭环存不存在	「会反馈给产品」
结束后谁维护	产能会不会被吃光	「还是我们」且无边界
上次说「不建议做」是什么时候	有没有话语权	「尽量满足客户」

附录 H 主要资料来源

一手文件与官方公告

- [Palantir S-1](#)

- [Dev versus Delta: Demystifying Engineering Roles at Palantir](#)
- [OpenAI Deployment Company](#)
- [OpenAI Harness Engineering](#)
- [AWS Forward Deployed Engineering for Partners](#)
- [Anthropic × Accenture](#)

工程方法

- [Effective Context Engineering for AI Agents](#), Anthropic
- [Demystifying Evals for AI Agents](#), Anthropic
- [Harness Engineering for Self-Improvement](#), Lilian Weng, 2026-07

调研数据

- [The GenAI Divide: State of AI in Business 2025](#), MIT Media Lab NANDA, 2025-07
- [LinkedIn 劳动力市场报告](#), 2026-01

背景

- [Forward Deployed Engineer \(维基百科\)](#)
- [《前线部署工程师》开源仓库](#), 范冰

关于这本书

创建者：空格 最后更新：2026-08-31

书里的方法论是从上述公开材料中抽象出来的。凡是我的推断，正文里写成"我认为""我的判断是"。第七篇的三个场景是推演，不是真实客户项目。